

UNIVERSIDADE FEDERAL DO RIO GRANDE DO SUL
INSTITUTO DE INFORMÁTICA
CURSO DE ENGENHARIA DE COMPUTAÇÃO

PEDRO VITOR ALEXANDRE

**Solução Computacional de Suporte à
Decisão e Análise Cienciométrica de
Periódicos Acadêmicos**

Monografia apresentada como requisito parcial
para a obtenção do grau de Bacharel em
Engenharia da Computação

Orientador: Prof^a. Dr^a. Lucinéia Heloisa Thom
Co-orientador: Prof. Dr. Márcio Dorn

Porto Alegre
2026

UNIVERSIDADE FEDERAL DO RIO GRANDE DO SUL

Reitora: Prof^ª. Marcia Cristina Bernardes Barbosa

Vice-Reitor: Prof. Pedro de Almeida Costa

Pró-Reitora de Graduação: Prof^ª. Nádyá Pesce da Silveira

Diretor do Instituto de Informática: Prof. Luciano Paschoal Gaspary

Coordenador do Curso de Engenharia de Computação: Prof. Paulo Francisco Butzen

Bibliotecário-chefe do Instituto de Informática: Alexsander Borges Ribeiro

*“If I have seen farther than others,
it is because I stood on the shoulders of giants.”*

— SIR ISAAC NEWTON

AGRADECIMENTOS

Agradeço ao L^AT_EX por não ter vírus de macro...

RESUMO

Revistas científicas e pesquisadores geram e manipulam volumes massivos de metadados cienciométricos, os quais frequentemente permanecem subutilizados devido à fragmentação de ferramentas e barreiras de usabilidade do estado da arte. Este trabalho apresenta o projeto, desenvolvimento e validação de uma solução computacional unificada e de código aberto voltada ao suporte à decisão na gestão estratégica de periódicos acadêmicos e à automação metodológica de Revisões Sistemáticas da Literatura (RSL). O sistema estende a arquitetura prototípica baseada em Python e Streamlit, substituindo motores de busca síncronos pela integração de alto desempenho com a API do OpenAlex em regime de *Polite Pool*. A plataforma incorpora um ecossistema agnóstico para ingestão e harmonização de múltiplos formatos (CSV, Excel, BibTeX, RIS e NBIB/PubMed), módulos vetorizados de cálculo de indicadores de impacto, concentração e obsolescência, além de motores avançados sob demanda para processamento de linguagem natural (BERTopic e GSDMM), detecção de comunidades em redes complexas (Método de Louvain) e auditorias de governança editorial. A validação empírica da robustez e usabilidade da arquitetura é conduzida por meio de um estudo de caso aplicado ao acervo histórico da Revista de Informática Teórica e Aplicada (RITA) da Universidade Federal do Rio Grande do Sul (UFRGS).

Palavras-chave: Análise bibliométrica. cienciometria. processamento de linguagem natural. gestão editorial. revisão sistemática da literatura. engenharia de software.

Computational Decision Support and Scientometric Analysis Solution for Academic Journals

ABSTRACT

Academic journals and researchers produce and process massive amounts of scientometric metadata, which often remain underutilized due to software fragmentation and usability barriers in current state-of-the-art tools. This work presents the design, implementation, and empirical validation of an open-source, unified computational decision-support solution for the strategic management of academic journals and the operational support of Systematic Literature Reviews (SLR). The system builds upon a lightweight Python and Streamlit prototype, optimizing data pipelines by integrating the OpenAlex API under the Polite Pool protocol for high-performance metadata enrichment. The solution provides an agnostic ingestion layer supporting multiple bibliographic formats (CSV, Excel, BibTeX, RIS, and NBIB/PubMed), vectorized modules for calculating impact, inequality, and obsolescence metrics, as well as on-demand engines for natural language processing (BERTopic and GSDMM), community detection in complex networks (Louvain Method), and editorial governance auditing. The architecture is validated through a practical case study analyzing the historical publication dataset of the Revista de Informática Teórica e Aplicada (RITA) at the Federal University of Rio Grande do Sul (UFRGS).

Keywords: bibliometric analysis, scientometrics, natural language processing, editorial management, systematic literature reviews, software engineering.

LISTA DE ABREVIATURAS E SIGLAS

API	<i>Application Programming Interface</i>
BERT	<i>Bidirectional Encoder Representations from Transformers</i>
BoW	<i>Bag-of-Words</i>
c-TF-IDF	<i>Class-Based Term Frequency-Inverse Document Frequency</i>
COPE	<i>Committee on Publication Ethics</i>
CSV	<i>Comma-Separated Values</i>
DOI	<i>Digital Object Identifier</i>
DSR	<i>Design Science Research</i>
DTM	<i>Dynamic Topic Models</i>
GIS	<i>Geographic Information System</i>
GSDMM	<i>Gibbs Sampling Dirichlet Multinomial Mixture</i>
HDBSCAN	<i>Hierarchical Density-Based Spatial Clustering of Applications with Noise</i>
HTML	<i>HyperText Markup Language</i>
ISO	<i>International Organization for Standardization</i>
JSON	<i>JavaScript Object Notation</i>
LDA	<i>Latent Dirichlet Allocation</i>
LLM	<i>Large Language Model</i>
LPA	<i>Label Propagation Algorithm</i>
MeSH	<i>Medical Subject Headings</i>
NBIB	<i>National Center for Biotechnology Information / PubMed Format</i>
NLM	<i>National Library of Medicine</i>
NLTK	<i>Natural Language Toolkit</i>
NMF	<i>Non-Negative Matrix Factorization</i>
NNDSVD	<i>Non-Negative Double Singular Value Decomposition</i>

NPMI	<i>Normalized Pointwise Mutual Information</i>
OOM	<i>Out of Memory</i>
PICOC	<i>Population, Intervention, Comparison, Outcome, Context</i>
PLN	Processamento de Linguagem Natural
PMID	<i>PubMed Identifier</i>
PRISMA	<i>Preferred Reporting Items for Systematic Reviews and Meta-Analyses</i>
RBO	<i>Rank-Biased Overlap</i>
REST	<i>Representational State Transfer</i>
RIS	<i>Research Information Systems</i>
RITA	Revista de Informática Teórica e Aplicada
ROR	<i>Research Organization Registro</i>
RPM	Requisições por Minuto
RSL	Revisão Sistemática da Literatura
SciELO	<i>Scientific Electronic Library Online</i>
SIG	Sistema de Informação Geográfica
SLR	<i>Systematic Literature Review</i>
SMS	<i>Systematic Mapping Study</i>
TF-IDF	<i>Term Frequency-Inverse Document Frequency</i>
TPM	<i>Tokens por Minuto</i>
UFRGS	Universidade Federal do Rio Grande do Sul
UMAP	<i>Uniform Manifold Approximation and Projection</i>
VOS	<i>Visualization of Similarities</i>
WoS	<i>Web of Science</i>

LISTA DE FIGURAS

Figura 3.1 Visão geral da arquitetura em camadas e fluxo de processamento de dados da solução.	22
Figura 6.1 Descrição da Figura deve ir no topo	62
Figura 6.2 Exemplo de figura desenhada com o <code>environment picture</code>	62

LISTA DE TABELAS

Tabela 2.1 Comparativo analítico entre ferramentas cienciométricas do estado da arte e o protótipo base.....	19
Tabela 5.1 Matriz consolidada de funcionalidades e suporte decisório frente ao estado da arte.....	60
Tabela 6.1 Uma tabela de Exemplo.....	63

SUMÁRIO

1 INTRODUÇÃO	13
1.1 Problema de Pesquisa	14
1.2 Objetivos	14
1.2.1 Objetivo Geral	14
1.2.2 Objetivos Específicos	14
1.3 Organização do Trabalho	15
2 TRABALHOS RELACIONADOS E ANÁLISE DO ESTADO DA ARTE	16
2.1 Panorama das Ferramentas Cienciométricas Consolidadas.....	16
2.2 O Protótipo Base	17
2.3 Análise Crítica e Oportunidades de Pesquisa	19
3 ARQUITETURA E ENGENHARIA DA SOLUÇÃO PROPOSTA.....	21
3.1 Visão Geral da Arquitetura em Camadas	21
3.2 Pipeline de Ingestão e Saneamento Resiliente	23
3.3 Estratégia de Gerenciamento de Memória e Sessão	24
3.4 Delimitação de Escopo e Restrições Técnicas.....	25
4 METODOLOGIA	26
4.1 Preparo de Dados: Ingestão, Normalização, Enriquecimento e Exportação	26
4.1.1 Limitações das Ferramentas Consolidadas e Motivação	26
4.1.2 Estratégia de Ingestão e Seleção de Formatos Bibliográficos	27
4.1.3 Pipeline de Enriquecimento em Cinco Níveis (<i>Multi-Tier</i>)	28
4.1.4 Exportação Universal e Rastreabilidade PRISMA	29
4.2 Dashboard Principal: Métricas Clássicas, Desigualdade e Diagnóstico de Integridade.....	29
4.2.1 Limitações Conceituais e Operacionais das Ferramentas Existentes	30
4.2.2 Auditoria e Diagnóstico de Integridade do Corpus.....	31
4.2.3 Modelagem de Impacto e Desempenho Científico	31
4.2.4 Mensuração Econométrica de Desigualdade Citatória	32
4.2.5 Dinâmica Temporal de Obsolescência e Envelhecimento	33
4.3 Estratificação Temática Avançada com PLN: Ensemble Híbrido (BERTopic + GSDMM), Callon e GenAI	33
4.3.1 Limitações da Modelagem Clássica em Metadados Curtos	34
4.3.2 Arquitetura do Ensemble Temático Dual (BERTopic + GSDMM)	35
4.3.3 Rotulagem por Inteligência Artificial (GenAI) e Avaliação de Qualidade	36
4.3.4 Diagrama Estratégico de Callon e Dinâmica Temporal.....	37
4.3.5 Reuso Transversal, Persistência e Modo de Foco Global	38
4.4 Mapeamento Científico e Redes Topológicas: Co-Citação, Acoplamento e Análise de Co-Palavras.....	39
4.4.1 Limitações das Ferramentas Convencionais de Mapeamento	39
4.4.2 Modelagem Matemática das Tipologias de Rede	40
4.4.3 Desambiguação Heurística e Detecção de Comunidades	41
4.4.4 Centralidades Topológicas, Renderização Interativa e Exportação	42
4.5 Evolução Temporal e Fluxo Temático: Fatiamento Dinâmico, NMF e Diagrama de Sankey	43
4.5.1 Limitações das Abordagens Temporais Convencionais.....	43
4.5.2 Estratégias de Fatiamento Temporal e Fatoração Local via NMF	44
4.5.3 Rastreamento Longitudinal de Linhagens e Diagrama de Sankey	45
4.6 Indicadores de Governança Editorial e Auditoria de Endogenia Institucional	46
4.6.1 Relevância Regulatória e Limitações das Abordagens Manuais	46

4.6.2	Formalização Matemática do Índice e Higienização Amostral	47
4.6.3	Painel de Auditoria Forense e Alertas Regulatórios	48
4.7	Mapeamento Geográfico Global e Redes de Coautoria Transnacional	49
4.7.1	Gargalos em Metadados Espaciais e Limitações das Ferramentas Vigentes	49
4.7.2	Arquitetura de Desambiguação Espacial em Duas Camadas	50
4.7.3	Inferência Demográfica de Gênero e Auditoria de Representatividade.....	51
4.7.4	Visualização Coroplética e Grafo de Coautoria Transnacional	51
4.8	Assistente de Triagem PRISMA para Revisões e Mapeamentos Sistemáticos da Literatura	52
4.8.1	Gargalos Metodológicos em Protocolos de RSL e Limitações Concorrentes	53
4.8.2	Máquina de Estados de Triagem e Fila Interativa (Critérios PICOC)	53
4.8.3	Compilação do Diagrama PRISMA 2020 e Propagação Reativa	54
4.9	Mapeamento Demográfico de Diversidade de Gênero	55
4.10	Recomendação de Parcerias (<i>Reviewer Matcher</i>)	55
5	ESTUDO DE CASO E VALIDAÇÃO EXPERIMENTAL	56
5.1	Caracterização do Acervo Experimental (Revista RITA)	56
5.2	Avaliação de Desempenho do Duto de Ingestão e Enriquecimento	56
5.3	Análise Cienciométrica e Diagnóstico de Integridade	57
5.4	Estratificação Temática e Validação do Ensemble de PLN	57
5.5	Mapeamento Topológico de Redes e Fluxo Longitudinal (Sankey)	58
5.6	Auditoria de Governança Editorial e Conformidade Regulatória	58
5.7	Validação do Protocolo de Triagem PRISMA 2020	59
5.8	Síntese Comparativa frente ao Estado da Arte	59
6	CONSIDERAÇÕES FINAIS E TRABALHOS FUTUROS.....	61
6.1	Conclusões	61
6.2	Limitações.....	61
6.3	Trabalhos Futuros.....	61
6.4	Instruções: Figuras e tabelas	62
6.4.1	Formato de Figuras	63
6.4.2	Classificação dos etc.	63
6.5	Instruções: Sobre as referências bibliográficas.....	63
	REFERÊNCIAS.....	65

1 INTRODUÇÃO

O estado atual do meio de publicação científica e da pesquisa acadêmica cria um enorme e constante fluxo de metadados em cada nova edição publicada (DONTHU et al., 2021). Apesar do crescente número de documentos disponibilizados em repositórios abertos e indexadores comerciais, a escassez de plataformas analíticas integradas, acessíveis e computacionalmente eficientes impõe barreiras operacionais a pesquisadores e conselhos editoriais (ASANO; SÁNCHEZ; THOM, 2026; MORAL-MUNOZ et al., 2020). Devido às limitações dos recursos computacionais e a ausência de departamentos especiais de ciência de dados a maioria dos periódicos científicos acadêmicos seguem procedimentos manuais, limitando-se ao armazenamento de manuscritos e desperdiçando o potencial de indicadores cienciométricos (STUMPF, 1996; MARZIALE, 2014; NAZAROVETS; NAZAROVETS, 2025).

Paralelamente, pesquisadores engajados na condução de Revisões Sistemáticas da Literatura (RSL) e Estudos de Mapeamento Sistemático (SMS) enfrentam desafios análogos ao sintetizar grandes volumes bibliográficos (KITCHENHAM et al., 2009; PETERSEN et al., 2008). A exportação de dados brutos a partir de indexadores heterogêneos frequentemente resulta em conjuntos corrompidos por divergências de codificação de caracteres (*encoding*), perda de resumos e ausência de identificadores persistentes padronizados (como DOIs e afiliações institucionais ROR) (PRANCKUTÈ, 2021; PRIEM; PIWOWAR; ORR, 2022). As ferramentas analíticas consagradas na literatura cienciométrica — a exemplo de VOSviewer (ECK; WALTMAN, 2010), Bibliometrix (ARIA; CUCCURULLO, 2017), CiteSpace (CHEN, 2006) e SciMAT (COBO et al., 2012) — apresentam-se fragmentadas: operam predominantemente como visualizadores gráficos de linha final que exigem arquivos perfeitamente higienizados, ou executam processamento síncrono pesado em memória local, culminando em lentidão e falhas por estouro de memória (*Out-of-Memory* – OOM) ao manipular acervos de escala moderada (MORAL-MUNOZ et al., 2020).

Buscando mitigar essas restrições e fornecer uma solução local e acessível, Asano, Sánchez and Thom (2026) conceberam um protótipo precursor estruturado em linguagem Python sob o *framework* reativo Streamlit. Embora tal artefato tenha comprovado a viabilidade da análise bibliométrica interativa sobre planilhas eletrônicas, sua concepção inicial operava sob algumas limitações: dependência estrita de esquemas rígidos de arquivos Excel, consultas sequenciais e síncronas à API da Crossref (resultando em esperas

de horas para bases de teste), análise temática restrita a nuvens de palavras-chave brutas sem contexto semântico e inexistência de módulos voltados à governança editorial ou à triagem sistemática de evidências.

1.1 Problema de Pesquisa

A análise bibliométrica moderna demanda lidar com o problema da dependência de bases comerciais fechadas e a falta de tratamento de dados malformados. Ao mesmo tempo, exige a integração de algoritmos avançados de Processamento de Linguagem Natural (PLN) e Análise de Redes Complexas capazes de executar localmente no computador do usuário final sem consumo excessivo de memória. Levando isso em consideração e a oportunidade de expandir a Prova de Conceito (POC) de Asano, Sánchez and Thom (2026), formula-se a seguinte questão de pesquisa:

Como projetar, implementar e validar uma solução computacional modular e escalável no hardware do cliente, agnóstica a formatos bibliográficos heterogêneos e independente de bases comerciais fechadas, capaz de fornecer suporte analítico à governança editorial de periódicos e automatizar o pipeline de triagem e mapeamento cienciométrico para pesquisadores?

1.2 Objetivos

1.2.1 Objetivo Geral

Projetar, implementar e validar experimentalmente uma plataforma computacional de código aberto, execução local e interface reativa, que estenda e otimize a arquitetura de Asano, Sánchez and Thom (2026), fornecendo uma suíte integrada de suporte à decisão para a gestão de periódicos científicos e para a condução de revisões sistemáticas da literatura.

1.2.2 Objetivos Específicos

Para alcançar o objetivo geral, definem-se os seguintes objetivos específicos:

1. **Ingestão e Enriquecimento de Metadados:** Projetar e implementar um *pipeline* resiliente e tolerante a falhas para saneamento de formatos bibliográficos heterogê-

neos e enriquecimento automatizado via repositórios de dados abertos;

2. **Inteligência Analítica e Governança Editorial:** Desenvolver módulos analíticos para quantificação de impacto citatório, modelagem semântico-temática e auditoria de indicadores de governança e endogenia editorial;
3. **Triagem Sistemática e Exploração Visual:** Estruturar um ambiente interativo para condução de revisões da literatura baseado no protocolo PRISMA (PAGE et al., 2021) e exploração topológica de redes bibliométricas;
4. **Validação Experimental e Avaliação de Desempenho:** Avaliar o desempenho computacional da plataforma (tempo de processamento e consumo de memória) e demonstrar sua viabilidade prática por meio de estudo de caso com o acervo histórico de um periódico científico.

1.3 Organização do Trabalho

O presente documento está estruturado em seis capítulos. O Capítulo 2 contextualiza o estado da arte por meio de uma revisão crítica das ferramentas cienciométricas consolidadas na literatura, detalhando as características e as limitações operacionais do protótipo base precursor. Em seguida, o Capítulo 3 apresenta a arquitetura de *software* e a engenharia da solução proposta, expondo as decisões de projeto voltadas ao desacoplamento de camadas, ao controle reativo de interface e ao gerenciamento eficiente de memória.

No Capítulo 4 são apresentados os métodos e algoritmos que governam os módulos analíticos do sistema, abrangendo desde o saneamento e enriquecimento de dados em múltiplos níveis até a estratificação semântica por Processamento de Linguagem Natural, a análise de redes topológicas, o fluxo longitudinal de tópicos, a auditoria de governança editorial e a esteira de triagem de literatura. A validação experimental do sistema é descrita no Capítulo 5, no qual se avalia a aplicabilidade prática, a acurácia dos modelos e os ganhos computacionais obtidos sobre o acervo histórico da Revista de Informática Teórica e Aplicada (RITA), complementando com uma matriz comparativa frente aos sistemas do estado da arte. Por fim, o Capítulo 6 sintetiza as contribuições alcançadas, discute as limitações técnicas encontradas e elenca direcionamentos para trabalhos futuros.

2 TRABALHOS RELACIONADOS E ANÁLISE DO ESTADO DA ARTE

A produção científica crescente tem exigido o surgimento de métodos que permitam mapear domínios do conhecimento, medir o impacto de pesquisadores e decodificar redes de colaboração acadêmica (DONTHU et al., 2021; MORAL-MUNOZ et al., 2020). Contudo, a condução de estudos cienciométricos abrangentes depende intrinsecamente da capacidade dos *softwares* de suportar múltiplas bases de dados, tratar metadados ruidosos e fornecer análises interpretáveis em tempo hábil (MORAL-MUNOZ et al., 2020).

Neste capítulo, examinam-se criticamente os principais *softwares* e pacotes bibliométricos consolidados na literatura científica, detalha-se a arquitetura e as limitações operacionais do protótipo precursor desenvolvido por Asano, Sánchez and Thom (2026), e sintetizam-se as lacunas tecnológicas que motivam a solução proposta neste trabalho.

2.1 Panorama das Ferramentas Cienciométricas Consolidadas

A seleção das ferramentas analisadas neste trabalho fundamenta-se nos levantamentos canônicos da literatura de mapeamento científico (MORAL-MUNOZ et al., 2020), contemplando as soluções de maior impacto e representatividade em diferentes paradigmas operacionais: visualização topológica *downstream*, ciencimetria estatística, detecção de rupturas temporais, análise longitudinal de temas e plataformas contemporâneas em nuvem. A seguir, discutem-se as características e os gargalos centrais dessas abordagens:

- **VOSviewer (ECK; WALTMAN, 2010):** Amplamente adotado em virtude de sua interface gráfica intuitiva e do algoritmo de posicionamento por similaridade (*Visualization of Similarities* – VOS). O VOSviewer destaca-se na renderização de redes bidimensionais de coautoria, co-citação e coocorrência de termos. No entanto, o *software* opera estritamente como um visualizador de linha final (*downstream*), pressupondo que o usuário forneça dados previamente higienizados nos formatos proprietários rígidos da *Web of Science* (WoS) ou *Scopus*. A ferramenta não oferece rotinas para ingestão agnóstica, correção de inconsistências sintáticas ou enriquecimento de dados faltantes.
- **Bibliometrix e Biblioshiny (ARIA; CUCCURULLO, 2017):** Desenvolvido como um pacote na linguagem R e complementado pela interface web *Biblioshiny*, o sis-

tema disponibiliza uma ampla gama de indicadores cientiométricos (leis de Bradford, Lotka e Zipf, acoplamento e matrizes de colaboração). Todavia, ao processar matrizes densas diretamente no escopo de memória da sessão do interpretador R, o ambiente apresenta alto consumo de memória RAM. Em bases moderadas a grandes (acima de 5.000 a 10.000 artigos), a aplicação frequentemente sofre com travamentos de sessão e estouro de memória (OOM), além de limitar sua ingestão nativa a poucas fontes comerciais (WoS, Scopus e Dimensions).

- **CiteSpace (CHEN, 2006):** *Software* baseado em Java projetado para identificar trajetórias evolutivas, pontos de inflexão e frentes emergentes de pesquisa por meio de algoritmos de detecção de explosão de atividade (*burst detection*) e caminhos de co-citação. Apesar de seu valor para a cienciometria teórica, o CiteSpace impõe uma curva de aprendizado íngreme, requer parametrizações manuais exaustivas de cortes temporais e tende à saturação visual (*spaghetti graphs*) em grafos densos, além de manifestar instabilidade em bases de menor escala.
- **SciMAT (COBO et al., 2012):** Focado no mapeamento longitudinal da evolução temática da ciência por meio do Diagrama Estratégico de Callon e de matrizes de co-terms. O SciMAT estrutura a evolução em períodos históricos sucessivos, mas exige processos manuais de migração e normalização de entidades em bancos de dados relacionais locais, carecendo de mecanismos automatizados para recuperação de resumos e desambiguação via APIs abertas.
- **Plataformas Web Fechadas (ex: Connected Papers):** Aplicações *web* contemporâneas oferecem navegação fluida em grafos de similaridade bibliográfica e resumos visuais. Contudo, operam como serviços comerciais fechados (*software as a service*), sem suporte para o carregamento de bases bibliográficas locais de periódicos institucionais, restringindo o usuário aos grafos pré-computados por suas próprias bases de indexação.

2.2 O Protótipo Base

Para mitigar a dependência excessiva das bases comerciais restritas (WoS e Scopus) e simplificar o fluxo de análise para pesquisadores não especializados em programação, Asano, Sánchez and Thom (2026) propuseram um artefato computacional fundamentado na metodologia *Design Science Research* (DSR) (PEFFERS et al., 2007).

A ferramenta desenvolvida por Asano, Sánchez and Thom (2026) foi estruturada na linguagem Python utilizando o *framework* Streamlit para renderização de interface web. O sistema estabeleceu a ingestão de metadados tabulares via arquivos Excel (*.xlsx/.xls*), permitindo que o usuário manipulasse registros bibliográficos de forma acessível e acionasse chamadas REST à API pública da Crossref para preenchimento de campos ausentes (como resumos, contagem de citações e referências). No módulo analítico, o protótipo implementou o cálculo do Índice-*h* clássico, Índice-*g*, Curva de Lorenz e Coeficiente de Gini, além de redes de co-citação e acoplamento bibliográfico renderizadas interativamente via biblioteca *Pyvis*.

Apesar dos avanços em usabilidade, a avaliação empírica do protótipo de Asano, Sánchez and Thom (2026) evidenciou limitações arquiteturais e computacionais que inviabilizavam sua aplicação em escala de produção:

1. **Ingestão Rígida de Dados:** O sistema exigia um esquema estrito de nomes de colunas no arquivo Excel (Author, Title, Abstract, Article Reference, Times Cited, Publication Year, DOI). Arquivos que apresentassem variações de nomenclatura, esquemas bibliográficos canônicos (BIBTEX, RIS, NBIB) ou inconsistências de codificação de caracteres resultavam em falha imediata de leitura.
2. **Gargalo de Desempenho em Consultas Síncronas à Crossref:** A rotina de enriquecimento iterava linha a linha sobre o conjunto de dados, disparando requisições HTTP sequenciais e síncronas à API da Crossref. Em experimentos práticos conduzidos com uma base de 10.000 artigos do PubMed, o processo de recuperação demandou **mais de duas horas por campo consultado**, além de sofrer bloqueios temporários por excesso de requisições (*rate limiting*) e falhar na recuperação de artigos históricos desprovidos de DOI (ASANO; SÁNCHEZ; THOM, 2026).
3. **Mapeamento Semântico Superficial:** A análise de conceitos restringia-se a nuvens de palavras-chave baseadas em correspondência exata de termos em torno de uma palavra focal (*co-word focus*), sem capacidade de identificar sinonímia, polissemia ou intenções contextuais em textos curtos.
4. **Ausência de Suporte à Decisão Editorial e Revisão Sistemática:** O protótipo limitava-se a métricas cienciométricas gerais, não contemplando módulos para auditoria de endogenia institucional, governança ética de conselhos editoriais ou suporte a protocolos formais de triagem de literatura (PRISMA 2020).

2.3 Análise Crítica e Oportunidades de Pesquisa

A Tabela 2.1 sintetiza as vantagens e as limitações críticas das ferramentas do estado da arte e do protótipo precursor, evidenciando as lacunas que sustentam o desenvolvimento do presente trabalho.

Tabela 2.1: Comparativo analítico entre ferramentas cienciométricas do estado da arte e o protótipo base.

Ferramenta	Ambiente	Principais Vantagens	Limitações Críticas Identificadas
VOSviewer (ECK; WALTMAN, 2010)	Desktop (Java)	Projeção eficiente de grandes grafos baseada no algoritmo VOS.	Opera apenas na linha final; requer dados pré-higienizados e formatos rígidos (WoS/Scopus).
Bibliometrix (ARIA; CUCCURULLO, 2017)	R / Shiny	Vasto repertório de leis clássicas e indicadores bibliométricos.	Alto consumo de RAM e falhas de <i>Out-of-Memory</i> no cliente; restrito a poucas bases.
CiteSpace (CHEN, 2006)	Desktop (Java)	Detecção de explosão temática (<i>burst</i>) e trajetórias históricas.	Curva de aprendizado severa; saturação visual em redes densas e parametrização rígida.
SciMAT (COBO et al., 2012)	Desktop (Java)	Mapeamento longitudinal por Diagrama de Callon em épocas.	Exige migração manual para banco relacional local; ausência de APIs de enriquecimento.
Connected Papers	Web (Fe-chada)	Navegação visual interativa e resumos de similaridade de fácil leitura.	Sistema proprietário fechado; não permite o carregamento de bases customizadas locais.
Protótipo Base (ASANO; SÁNCHEZ; THOM, 2026)	Python / Streamlit	Ingestão via planilhas e integração com API aberta da Crossref.	Consultas síncronas lentas; restrito a Excel rígido; ausência de PLN avançado.

A partir do diagnóstico das limitações apresentadas, este trabalho propõe uma plataforma unificada que transforma a Prova de Conceito de Asano, Sánchez and Thom (2026) em um ambiente robusto, escalável e abrangente de engenharia de dados e suporte à decisão. As principais inovações frente aos trabalhos relacionados concentram-se em:

- **Ingestão Agnóstica e Tolerante a Falhas:** Suporte nativo a CSV, Excel, BIB_{TE}X, RIS e NBIB (PubMed), com detecção heurística de codificações e delimitadores;
- **Pipeline de Enriquecimento em 5 Níveis:** Substituição de consultas síncronas lentas por requisições em lote de 50 itens via OpenAlex sob *Polite Pool* e *cache* em disco, complementadas por múltiplos níveis de *fallback* (Crossref, PubMed,

Semantic Scholar e busca aproximada por título);

- **Estratificação Semântica por Ensemble de PLN:** Combinação colaborativa de representações densas contextuais (BERTopic) com o modelo probabilístico para textos curtos (GSDMM), complementada por rotulagem conceitual automática via Modelos de Linguagem de Grande Porte (LLMs);
- **Fluxo Longitudinal e Governança Editorial:** Introdução do Diagrama de Sankey com fatiamento dinâmico por quantis para mapear a transição de paradigmas científicos, e concepção de módulo inédito para auditoria de endogenia institucional alinhado aos critérios regulatórios de indexadores (como SciELO);
- **Integração ao Protocolo PRISMA 2020:** Conexão da esteira de ingestão a uma fila reativa de triagem de literatura para revisões sistemáticas, compilando diagramas de fluxo oficiais em Graphviz/DOT em tempo real.

3 ARQUITETURA E ENGENHARIA DA SOLUÇÃO PROPOSTA

Para solucionar as limitações de acoplamento, sobrecarga de memória e rigidez de formatos identificadas nos softwares cienciométricos convencionais, a solução proposta foi projetada sob o padrão arquitetural em camadas (*Layered Architecture*) integrado ao modelo de processamento em dutos e filtros (*Pipeline-and-Filter*). Essa abordagem assegura o desacoplamento entre os algoritmos analíticos, o ciclo de vida da interface reativa e as rotinas de persistência.


Neste capítulo, são detalhadas a visão geral da arquitetura em cinco macrocamadas, as decisões de engenharia utilizados na construção da ingestão e enriquecimento de dados, a gestão determinística de memória em sessão e a matriz de restrições operacionais do sistema.

3.1 Visão Geral da Arquitetura em Camadas

A arquitetura do sistema está estruturada em cinco camadas lógicas encadeadas, conforme ilustrado na Figura 3.1:

1. **Camada de Ingestão Agnóstica Multiformato:** Responsável pelo recebimento e sanitização inicial de arquivos locais nos cinco formatos suportados (BIB_{TEX}, RIS, NBIB, CSV e Excel), tratando imperfeições sintáticas e unificando os atributos em um esquema padrão;
2. **Motor de Enriquecimento Resiliente (*Multi-Tier*):** Executa a complementação assíncrona de metadados ausentes (como resumos, identificadores ROR e listas de referências) através de consultas em lote e múltiplos níveis de contingência (*fallback*);
3. **Gerenciamento de Estado e Memória Reativa:** Centraliza o armazenamento do conjunto de dados mestre em sessão (*master_df*), provendo controle de concorrência, filtros globais e isolamento contra mutações destrutivas;
4. **Módulos Analíticos e Suporte à Decisão:** Conjunto de subsistemas que realizam cálculos cienciométricos, modelagem semântica de linguagem natural, representações gráficas e métricas de governança editorial;
5. **Camada de Apresentação e Exportação Universal:** Interface *web* reativa construída sobre o *framework* Streamlit, encarregada da renderização de componentes

Figura 3.1: Visão geral da arquitetura em camadas e fluxo de processamento de dados da solução.



interativos e da serialização reversa dos dados enriquecidos para uso externo.

3.2 Pipeline de Ingestão e Saneamento Resiliente

O módulo de ingestão (`core/ingestion.py`) foi construído para operar de forma tolerante a falhas, mitigando a sensibilidade estrutural típica de soluções em R/Shiny.

Para processar arquivos tabulares separados por delimitados, implementou-se uma rotina de detecção heurística que testa sequencialmente diferentes tabelas de codificação de caracteres (`utf-8`, `latin1`, `cp1252` e `iso-8859-1`) combinadas com inferência dinâmica do delimitador de campo (`csv.Sniffer`). Quando surgem anomalias devido ao término de linha inconsistente no caso de registros longos, o sistema executa reconstrução em memória via `io.StringIO` orientada por expressões regulares. Para formatos semiestruturados biomédicos, foi construído um analisador baseado em Máquina de Estados Finitos (`parse_nbib`), capaz de extrair *tags* de múltiplas linhas da *National Library of Medicine*.

Concluída a extração, o conjunto de dados passa por três filtros determinísticos de saneamento:

- **Mapeamento para Esquema Canônico (17 Dimensões):** Dicionários semânticos traduzem mais de 50 variações de cabeçalhos brutos (e.g., “*Abstract*”, “*Resumo*”, “*AB*”) mapeados para o formato padronizado `TARGET_COLUMNS`;
- **Fusão Horizontal Não-Destrutiva (*bfill*):** Caso colunas homônimas coexistam em virtude de exportações parciais anteriores, aplica-se preenchimento retroativo no eixo horizontal (`bfill(axis=1)`), consolidando valores válidos sem sobreposição de dados;
- **Deduplicação Multi-Chave com Proteção de Nulos:** A eliminação de duplicatas ocorre em dois estágios (normalização de prefixos DOI e tratamento léxico de títulos em caixa baixa). Para assegurar que artigos históricos sem DOI não sejam excluídos em massa, valores ausentes são temporariamente preenchidos pelo índice único do registro (`fillna(df.index)`).

3.3 Estratégia de Gerenciamento de Memória e Sessão

Diferentemente de ferramentas consolidadas que instanciam matrizes esparsas globais pesadas, a solução proposta gerencia o estado operacional por meio do objeto reativo `st.session_state`. A integridade da aplicação apoia-se em três decisões de engenharia:

- **Teto Operacional de Segurança (`MAX_ROWS`):** Estabeleceu-se um limiar paramétrico padrão de 50.000 registros para preservar a estabilidade da pilha de execução e a fluidez de renderização no navegador do cliente;
- **Preservação Não-Destrutiva do Estado Bruto (`raw_df_backup`):** As alterações realizadas em módulos de triagem (como exclusões no Assistente PRISMA) ou filtros exploratórios operam sobre uma visão de trabalho derivada (`working_df`), mantendo o conjunto original intacto até a confirmação explícita (`commit`) do usuário;
- **Propagação do Modo de Foco Global (*Global Focus Mode*):** A seleção de tópicos específicos na interface propaga uma lista reativa de identificadores (`focus_topics`), instruindo os módulos analíticos a recalcular dinamicamente grafos e métricas de impacto exclusivamente sobre o subconjunto ativo, sem duplicar matrizes em memória;
- **Persistência Atômica dos Estados de Sessão:** Para eliminar o custo de reprocessar modelos pesados de aprendizado de máquina a cada novo acesso, o módulo serializa os agrupamentos temáticos, rótulos conceituais e parâmetros calculados em arquivo estruturado JSON (`clean_floats`), restaurando o estado analítico integral de forma atômica.

A arquitetura de gerenciamento de estado da aplicação é projetada para acoplar a reatividade de dados à experiência analítica do usuário. Para isso, a interface implementa um sistema de roteamento baseado em perfis de uso (`ALL`, `RESEARCHER` e `EDITORIAL`), que adapta a quantidade de informações e recursos exibidas ao nível de profundidade exigido pelo contexto do usuário. Sendo assim, recursos como `XX` são exclusivos do perfil para pesquisadores, enquanto `XX` são exclusivos do perfil para editoriais.

3.4 Delimitação de Escopo e Restrições Técnicas

Para garantir a viabilidade operacional e a independência de infraestruturas proprietárias de nuvem, o projeto delimita-se sob as seguintes condições técnicas de contorno:

1. **Execução Local no Cliente:** A plataforma não depende de servidores centrais de banco de dados, rodando integralmente no ambiente local do usuário sob o interpretador Python 3.10+;
2. **Aderência a Protocolos e Políticas de APIs Externas :** As consultas a serviços externos submetem-se estritamente às regras de consumo vigentes de cada provedor. Para os indexadores acadêmicos (OpenAlex, Crossref e PubMed), observam-se as políticas de *Polite Pool* e limites de requisição públicos. Para os provedores de Modelos de Linguagem (OpenAI e Gemini), o sistema respeita rigorosamente as cotas de autenticação, limites de requisições por minuto (RPM) e volumes de *tokens* (TPM) estabelecidos em suas respectivas documentações oficiais;
3. **Privacidade e Soberania de Dados:** Todo o processamento de textos, deduplicação e auditoria de afiliações institucionais é executado em memória volátil local, assegurando que manuscritos não publicados e dados editoriais sensíveis permaneçam sob controle exclusivo da equipe do periódico. Nenhuma chave de API do usuário é armazenada para uso posterior ou compartilhada.

4 METODOLOGIA

Cada recurso da arquitetura demonstrada no capítulo 3 foi desenvolvido pensando no estado da arte atual (como é possível encontrar este recurso em outros sistemas) para então ser feita uma análise possíveis otimizações com o intuito de agregar maior valor. Abaixo, detalhes de cada aglomerado de recursos ou *features*.

4.1 Preparo de Dados: Ingestão, Normalização, Enriquecimento e Exportação

O tratamento prévio de metadados bibliográficos representa uma das etapas mais sensíveis no *pipeline* de análise cienciométrica. A confiabilidade de análises posteriores — como redes de coautoria, acoplamento bibliográfico e modelagem temática — está diretamente condicionada à consistência dos dados de entrada. Nesta seção, discutem-se as limitações dos *softwares* atuais, as decisões metodológicas adotadas na construção da camada de ingestão e enriquecimento de dados, e a avaliação empírica do desempenho alcançado.

4.1.1 Limitações das Ferramentas Consolidadas e Motivação

Ferramentas amplamente adotadas pela comunidade científica apresentam entraves relevantes no que tange à usabilidade e à tolerância a dados heterogêneos (MORAL-MUNOZ et al., 2020):

- **Dependência de dados pré-higienizados:** Softwares consolidados de mapeamento, como o VOSviewer (ECK; WALTMAN, 2010), funcionam primordialmente como visualizadores de linha final. Eles assumem que o pesquisador já dispõe de bases perfeitamente estruturadas no padrão rígido da *Web of Science* ou da *Scopus*, não oferecendo recursos integrados para sanear inconsistências léxicas ou lidar com formatos bibliográficos variados.
- **Sobrecarga de memória em execuções locais:** Pacotes analíticos em R, a exemplo do *Bibliometrix/Biblioshiny* (ARIA; CUCCURULLO, 2017), carregam matrizes completas na memória da sessão. Quando aplicados a conjuntos moderados ou grandes (acima de 5.000 artigos), tornam-se suscetíveis a travamentos e estouros de memória (OOM), além de exigirem esforço manual para deduplicar registros entre

fontes distintas.

- **Inconsistências de codificação e delimitação:** Arquivos exportados por bases comerciais frequentemente apresentam problemas de *encoding* (como conflitos entre UTF-8 e Latin-1), perda de resumos por truncamento e erros de sintaxe em arquivos tabulares (como vírgulas não escapadas em campos de texto e delimitadores mistos) (PRANCKUTÈ, 2021).
- **Gargalos em enriquecimentos síncronos:** Abordagens anteriores, como a discutida no protótipo de Asano, Sánchez and Thom (2026), realizavam consultas síncronas e unitárias a uma única API (Crossref). Essa estratégia resulta em longas horas de espera para bases médias, vulnerabilidade a bloqueios de taxa de requisição (*rate limiting*) e impossibilidade de recuperar registros que não utilizam DOI (como trabalhos indexados pelo PubMed via PMID ou literatura cinzenta).

4.1.2 Estratégia de Ingestão e Seleção de Formatos Bibliográficos

Para superar a dependência de formatos proprietários fechados, definiu-se uma estratégia de ingestão agnóstica capaz de processar simultaneamente cinco padrões bibliográficos representativos do meio acadêmico:

1. **BIBTEX (.bib):** Padrão canônico em Ciências da Computação, Engenharia e Matemática, essencial para pesquisadores que redigem seus manuscritos em L^AT_EX.
2. **RIS (.ris):** Formato de intercâmbio universal suportado por bases indexadoras globais (IEEE Xplore, Scopus, Web of Science) e pelos principais gerenciadores de referências do mercado, como Zotero, Mendeley e EndNote.
3. **NBIB (.nbib):** Padrão estruturado da *National Library of Medicine* (NLM/PubMed), fundamental para pesquisas nas áreas de Ciências Biológicas e da Saúde por preservar descritores controlados (*MeSH terms*).
4. **CSV e Excel (.csv, .xlsx, .xls):** Formatos tabulares amplamente acessíveis que facilitam a inspeção preliminar, filtros manuais e a interoperabilidade com bibliotecas analíticas em Python e R.

Para garantir que o carregamento desses arquivos ocorra sem falhas, o módulo de ingestão (`core/ingestion.py`) adota um conjunto de regras de tolerância a falhas. Em arquivos CSV, a rotina testa iterativamente diferentes codificações (`utf-8`, `latin1`, `cp1252` e `iso-8859-1`) combinadas à inferência automática de delimitadores. Para

formatos estruturados biomédicos, desenvolveu-se um analisador sintático (*parser*) dedicado ao padrão NBIB, capaz de reconstruir resumos multilinhas e extrair identificadores persistentes.

Após a leitura, o conjunto de dados é harmonizado em um esquema padronizado de 17 colunas (`TARGET_COLUMNS`). Caso existam colunas com nomes equivalentes de correntes de bases mescladas, aplica-se uma consolidação horizontal retroativa (*backward fill*), evitando a perda de dados pré-existentes. Por fim, registros estruturalmente vazios ou sem identificadores essenciais são descartados, e o conjunto é armazenado na memória da sessão sob um teto de segurança configurável de 50.000 linhas para assegurar a responsividade da interface.

A deduplicação ocorre em duas etapas determinísticas: primeiro, pela padronização do DOI (com preenchimento temporário por índice para que registros sem identificador não sejam eliminados em bloco); segundo, pela normalização textual dos títulos em caixa baixa, sem espaçamentos residuais.

4.1.3 Pipeline de Enriquecimento em Cinco Níveis (*Multi-Tier*)

Para complementar lacunas de metadados — especialmente resumos, afiliações e termos temáticos —, estruturou-se um pipeline de enriquecimento hierárquico em cascata (`core/enrichment.py`). Todas as requisições operam sob o regime de *Polite Pool* (com cabeçalho HTTP identificado) e utilizam uma camada de *cache* persistente em disco com validade de sete dias, mitigando tráfego redundante de rede. A cascata é composta por cinco etapas sequenciais:

- **Nível 1 (OpenAlex em Lote):** Agrupa os DOIs válidos em lotes de 50 registros por consulta (`filter=doi:...`), consumindo o ecossistema unificado do OpenAlex (PRIEM; PIWOWAR; ORR, 2022). Nesta etapa, resumos são reconstruídos a partir do índice invertido, e afiliações institucionais são extraídas e padronizadas.
- **Nível 2 (Crossref REST API):** Atua como *fallback* editorial sob demanda para registros cujos DOIs não retornaram dados no Nível 1, recuperando ano de publicação, editora e autoria canônica.
- **Nível 3 (PubMed eUtils API):** Acionado especificamente para artigos identificados por PMID que necessitem de resumo ou descritores temáticos MeSH (*Medical Subject Headings*).

- **Nível 4 (Semantic Scholar API):** Consulta a base do Semantic Scholar para resgatar resumos faltantes ou sínteses automáticas geradas por inteligência artificial (*TLDR*).
- **Nível 5 (Busca Aproximada por Título no OpenAlex):** Desenvolvido especialmente para publicações sem DOI (como literatura cinzenta, periódicos regionais e anais históricos de conferências). Executa uma busca por similaridade textual (*fuzzy search*) via endpoint `title.search`, recuperando metadados de itens antes inacessíveis.

O processo registra automaticamente um arquivo de auditoria em disco (`.log`), permitindo monitorar a taxa de sucesso de cada API e verificar quais registros permaneceram com campos ausentes ao término da execução.

4.1.4 Exportação Universal e Rastreabilidade PRISMA

Concluído o saneamento e o enriquecimento, o sistema permite a reexportação integral da base saneada de volta para os formatos CSV, Excel (via buffer binário em memória), RIS, BIB_{TEX} e NBIB (`core/export.py`). Na geração do BIB_{TEX}, o motor formata as cadeias de múltiplos autores para o padrão exigido por compiladores L_AT_EX (`Autor A and Autor B`).

Para atender às boas práticas de Ciência Aberta e garantir a reprodutibilidade metodológica, o sistema mantém o controle de proveniência de cada arquivo carregado. Essa contagem discriminada de registros brutos, duplicatas expurgadas e entradas finais enriquece o preenchimento do diagrama de fluxo preconizado pela declaração PRISMA 2020 (PAGE et al., 2021), conferindo transparência à seleção amostral da pesquisa.

4.2 Dashboard Principal: Métricas Clássicas, Desigualdade e Diagnóstico de Integridade

A avaliação científica de um determinado periódico ou grupo de periódicos não pode se limitar apenas à descrição estatística do número de artigos e citações. Para que editores e pesquisadores tomem decisões embasadas, é necessário validar a qualidade da informação que está sendo analisada, identificar a real distribuição de impacto entre os autores e compreender o ritmo de envelhecimento da literatura. Nesta seção, são apresen-

tadas as limitações dos painéis convencionais, a formalização das métricas de impacto e desigualdade implementadas, as rotinas de auditoria de dados e os ganhos de desempenho obtidos por meio de computação vetorizada.

4.2.1 Limitações Conceituais e Operacionais das Ferramentas Existentes

Os visualizadores bibliométricos tradicionais, como VOSviewer, CiteSpace, e interfaces baseadas em R/Shiny como o Biblioshiny (ARIA; CUCCURULLO, 2017; MORAL-MUNOZ et al., 2020) costumam apresentar gargalos conceituais e operacionais que restringem análises aprofundadas:

- **Insensibilidade a artigos de impacto extraordinário (*blockbusters*):** O amplamente utilizado Índice- h de Hirsch (HIRSCH, 2005) impõe um limite intrínseco: ele desconsidera a cauda superior de citações. Dessa forma, um autor que possua h artigos com exatamente h citações terá a mesma pontuação que outro cujos mesmos h artigos acumularam milhares de citações, nivelando artificialmente perfis científicos bastante distintos.
- **Processamento cego de dados com lacunas (“caixas-pretas”):** A maioria dos softwares projeta gráficos e contagens diretamente sobre a base de entrada sem alertar o pesquisador sobre o percentual de campos nulos (como resumos ausentes, anos corrompidos ou afiliações não identificadas). Essa ausência de diagnóstico prévio induz a conclusões enviesadas sem auditoria de qualidade amostral.
- **Ausência de métricas econométricas de concentração:** A distribuição de citações na ciência segue distribuições altamente assimétricas, regidas por leis de potência (ALBARRÁN et al., 2011). Contudo, os visualizadores convencionais raramente integram medidas formais de desigualdade, como a Curva de Lorenz e o Coeficiente de Gini, impossibilitando que corpos editoriais avaliem se o prestígio de um periódico decorre de uma produção homogênea ou do impacto concentrado em poucos manuscritos.
- **Sobrecarga de renderização e acoplamento síncrono:** Ambientes como o Biblioshiny constroem tabelas e matrizes densas diretamente no escopo global da sessão. Ao processar acervos com dezenas de milhares de citações e autores desnormalizados, essas ferramentas frequentemente enfrentam lentidão, perda de responsividade e quebras de interface.

4.2.2 Auditoria e Diagnóstico de Integridade do Corpus

Para garantir que a análise seja metodologicamente confiável, o sistema incorpora um módulo de diagnóstico visual de qualidade de dados (`display_error_info`), acionado antes da interpretação dos indicadores.

O diagnóstico opera sobre uma cópia normalizada do conjunto de dados e classifica as inconsistências em duas categorias:

- **Colunas do Esquema Canônico (*Main Schema*):** Avalia individualmente a taxa de preenchimento dos 17 atributos fundamentais (`TARGET_COLUMNS`), como DOI, título, autor, resumo e ano de publicação, exibindo um gráfico de barras ordenado pelo percentual de campos faltantes.
- **Colunas Secundárias (*Non-Schema*):** Mapeia campos adicionais ou específicos da base de origem que não integram o esquema principal, organizando-os em um painel expansível de apoio.

Além da visualização gráfica, o sistema disponibiliza um seletor dinâmico que permite ao usuário isolar e inspecionar visualmente as linhas que contêm valores nulos ou vazios (`is_nan` ou `is_empty`) para cada coluna selecionada. Esse subconjunto deficitário pode ser exportado diretamente em formato CSV, viabilizando correções manuais pontuais ou rotinas de saneamento externo.

4.2.3 Modelagem de Impacto e Desempenho Científico

A avaliação do impacto individual de autores e do acervo como um todo combina formulações clássicas e complementares da cienciometria, calculadas por meio de rotinas vetorizadas em memória.

Para viabilizar a análise no nível de autor, o sistema efetua o desdobramento relacional do campo `Author` (delimitado por vírgula) por meio de uma operação encadeada de particionamento e descompactação (`df.assign().explode()`), complementada pela remoção de espaçamentos residuais. Esse pré-processamento elimina laços iterativos lentos e escala eficientemente sobre grandes acervos.

A mensuração de impacto combina dois indicadores centrais:

- **Índice- h de Hirsch (HIRSCH, 2005):** Dado um conjunto de N artigos de um pesquisador dispostos em ordem decrescente de citações ($c_1 \geq c_2 \geq \dots \geq c_N$), o

Índice- h corresponde ao maior valor inteiro h tal que os primeiros h artigos tenham recebido individualmente pelo menos h citações:

$$h = \max\{i \in \{1, \dots, N\} : c_i \geq i\} \quad (4.1)$$

- **Índice- g de Egghe (EGGHE, 2006):** Proposto para valorizar adequadamente manuscritos com volume expressivo de citações que extrapolam o limiar do h -index, o Índice- g é definido como o maior número inteiro g tal que os primeiros g artigos mais citados acumulem, conjuntamente, ao menos g^2 citações:

$$g = \max \left\{ i \in \{1, \dots, N\} : \sum_{j=1}^i c_j \geq i^2 \right\} \quad (4.2)$$

A partir dessas formulações, o sistema sintetiza rankings interativos dos dez autores mais produtivos e mais citados (`nlargest(10)`), disponibilizando tabelas sumarizadas com contagem total de publicações, soma de citações, média por artigo e ambos os índices calculados, com suporte a download instantâneo dos resultados.

4.2.4 Mensuração Econométrica de Desigualdade Citatória

Para identificar se o prestígio e a visibilidade de um periódico estão amplamente distribuídos ou concentrados em uma minoria de artigos, o sistema adapta conceitos clássicos da econometria à análise cienciométrica (LORENZ, 1905; GINI, 1912).

A **Curva de Lorenz** modela a função de distribuição acumulada de citações. Considerando um vetor de n artigos ordenados de forma crescente por citações, $c_{(1)} \leq c_{(2)} \leq \dots \leq c_{(n)}$, a fração acumulada de manuscritos no ponto i é dada por $x_i = i/n$, enquanto a proporção acumulada de citações recebidas é definida por:

$$L(x_i) = \frac{\sum_{k=1}^i c_{(k)}}{\sum_{k=1}^n c_{(k)}}, \quad \text{onde } x_i \in [0, 1] \text{ e } L(x_i) \in [0, 1] \quad (4.3)$$

A visualização contrasta a Curva de Lorenz gerada interativamente contra a Reta de Perfeita Igualdade ($y = x$). O distanciamento entre as duas linhas evidencia visualmente o grau de assimetria do acervo.

Complementarmente, o **Coefficiente de Gini** (G) quantifica essa assimetria em um valor escalar contido no intervalo $[0, 1]$, implementado pela formulação discreta para

vetores ordenados:

$$G = \frac{n + 1 - 2 \left(\frac{\sum_{i=1}^n S_i}{S_n} \right)}{n} \quad (4.4)$$

em que $S_i = \sum_{k=1}^i c_{(k)}$ representa a soma parcial acumulada até o i -ésimo registro e S_n denota o montante total de citações do acervo. Valores de G próximos de zero expressam distribuição homogênea entre os artigos, enquanto valores próximos de um revelam extrema hiperconcentração de impacto.

4.2.5 Dinâmica Temporal de Obsolescência e Envelhecimento

A evolução temporal da literatura e a velocidade de assimilação do conhecimento são avaliadas por meio da agregação cronológica da produção científica (GARFIELD, 1972).

O campo `Publication Year` é previamente saneado via expressões regulares `((?:18|19|20)\d{2})`, isolando anos válidos de textos corrompidos. Em seguida, operações de agrupamento (`groupby`) constroem duas séries temporais paralelas: o volume anual de publicações e a quantidade agregada de citações recebidas por ano.

Para calcular a curva de **Citações Médias por Artigo** ao longo dos anos sem o risco de interrupções por indeterminações matemáticas em anos sem publicações, a divisão elemento a elemento é protegida por tratamento explícito de exceções de ponto flutuante (`np.errstate`):

$$\bar{C}_Y = \begin{cases} \frac{C_Y}{P_Y}, & \text{se } P_Y > 0 \\ \text{NaN}, & \text{se } P_Y = 0 \end{cases} \quad (4.5)$$

em que C_Y representa o volume de citações acumuladas e P_Y o número de artigos publicados no ano Y . As indeterminações geradas são convertidas em valores nulos padronizados, preservando a continuidade dos gráficos temporais.

4.3 Estratificação Temática Avançada com PLN: Ensemble Híbrido (BERTopic + GSDMM), Callon e GenAI

A identificação de tópicos e frentes de pesquisa em artigos científicos pode ser considerada uma das tarefas mais nobres da cienciometria (CALLON et al., 1983). Con-

tudo, metadados bibliográficos (títulos, resumos e palavras-chave) impõem desafios singulares ao Processamento de Linguagem Natural (PLN), caracterizando-se como textos curtos e esparsos (CHURCHILL; SINGH, 2022; ALBALAWI; YEAP; BENYOUCEF, 2020). Nesta seção, são apresentadas as limitações dos modelos tradicionais, a concepção do modelo híbrido em *ensemble* (BERTopic e GSDMM), o motor de rotulagem conceitual por Modelos de Linguagem de Grande Porte (LLMs) (KHANDELWAL, 2025), a projeção no Diagrama Estratégico de Callon e a propagação transversal dos tópicos no sistema.

4.3.1 Limitações da Modelagem Clássica em Metadados Curtos

As abordagens comumente empregadas em *softwares* cienciométricos consolidados apresentam restrições conceituais importantes:

- **Reduccionismo da coocorrência léxica (*Co-word Analysis*):** Ferramentas como VOSviewer e Bibliometrix fundamentam seus agrupamentos conceituais na frequência bruta e coocorrência de termos (*exact string matching*). Essa técnica ignora fenômenos linguísticos fundamentais como polissemia, sinonímia e dependência sintática contextual, agrupando palavras estritamente por sua grafia.
- **Colapso do Latent Dirichlet Allocation (LDA) em textos curtos:** O modelo generativo do LDA (BLEI; NG; JORDAN, 2003) pressupõe que cada documento é uma mistura latente de múltiplos tópicos. Em títulos e resumos acadêmicos, a severa esparsidade da matriz termo-documento e a escassez de coocorrências impedem a convergência estável da amostragem de Gibbs, provocando sobreposição excessiva de *clusters* e degradação da coerência semântica (C_V) (PICENI; ALEXANDRE; BALREIRA, 2025).
- **Ausência de abordagens em consenso (*Ensemble*):** Ferramentas de mercado não combinam representações vetoriais densas baseadas em *Transformers* com métodos probabilísticos ajustados para textos concisos, forçando o pesquisador a escolher entre a opacidade contextual dos *embeddings* e a rigidez do *Bag-of-Words*.
- **Rotulagem manual, subjetiva e falta de persistência:** A identificação dos temas gerados em *softwares* legados depende da inspeção visual exaustiva de listas isoladas de palavras, sujeitando o processo a vieses do analista. Além disso, a ausência de mecanismos para salvar e recarregar o estado do modelo exige o reprocessa-

mento custoso de algoritmos de aprendizado de máquina a cada nova sessão.

4.3.2 Arquitetura do Ensemble Temático Dual (BERTopic + GSDMM)

Para superar a esparsidade de textos curtos e preservar a semântica contextual, o sistema implementa um *ensemble* que opera dois ramos complementares de modelagem: o neural denso (BERTopic) e o estocástico para textos curtos (GSDMM) (PICENI; ALEXANDRE; BALREIRA, 2025).

As exigências distintas de cada paradigma demandam um pré-processamento diferenciado. O ramo neural recebe o texto integral (título, resumo e palavras-chave) preservando pontuação, acentuação e *stopwords*, garantindo que o mecanismo de atenção do modelo multilíngue `paraphrase-multilingual-MiniLM-L12-v2` capture a semântica profunda em português e inglês. Em contrapartida, o ramo probabilístico (`preprocess_for_gsdmm`) aplica lematização rigorosa, conversão para caixa baixa e remoção estrita de *stopwords*, construindo um vocabulário compacto essencial para a convergência estatística.

1. **Ramo Neural – BERTopic (GROOTENDORST, 2022):** Mapeia o texto em vetores densos via *Sentence-BERT*, reduz a dimensionalidade preservando a topologia global e local através do algoritmo UMAP (MCINNES; HEALY; MELVILLE, 2018) e agrupa as regiões densas com o HDBSCAN (MCINNES; HEALY; AS-TELS, 2017), isolando automaticamente ruídos na classe de *outliers* (tópico -1). A representação léxica de cada *cluster* c é calculada pelo algoritmo c -TF-IDF:

$$W_{t,c} = \text{TF}_{t,c} \times \log \left(1 + \frac{A}{f_t} \right) \quad (4.6)$$

em que $\text{TF}_{t,c}$ indica a frequência do termo t na classe c , A é a contagem média de palavras por classe e f_t expressa a frequência global do termo no acervo.

2. **Ramo Probabilístico – GSDMM (YIN; WANG, 2014):** Implementa o modelo de Mistura Multinomial de Dirichlet baseado no Processo do Restaurante Chinês, assumindo que cada documento curto d trata prioritariamente de um único tópico latente. A probabilidade de alocação de d ao *cluster* k , condicionada aos demais

documentos ($\neg d$), é formulada por:

$$P(z = k \mid \vec{d}, \vec{z}_{\neg d}) \propto \frac{m_{k,\neg d} + \alpha}{D - 1 + K\alpha} \times \frac{\prod_{w \in d} (n_{k,w,\neg d} + \beta)}{\prod_{i=1}^{|d|} (N_{k,\neg d} + V\beta + i - 1)} \quad (4.7)$$

onde $m_{k,\neg d}$ é a contagem de documentos no tópico k , D o total de documentos, K o teto de tópicos, V o tamanho do vocabulário, $n_{k,w,\neg d}$ a frequência da palavra w no tópico k e α, β os hiperparâmetros simétricos de Dirichlet.

A harmonização dos dois modelos é executada pelo módulo de alinhamento (`align_topics` e `assign_unified_topics`). O algoritmo calcula uma matriz de similaridade semântica entre os vetores de palavras-chave extraídos pelo BERTopic e pelo GSDMM, consolidando as partições em um identificador único (`unified_topic`). Cada documento recebe um índice de confiança calibrado (`topic_confidence`), uma indicação de tópico secundário de fronteira (`secondary_topic`) e o rastreamento de eventuais instâncias não convergentes.

4.3.3 Rotulagem por Inteligência Artificial (GenAI) e Avaliação de Qualidade

Para eliminar a subjetividade na interpretação dos agrupamentos, o sistema integra o motor GenAI Naming Engine, conectando a interface a múltiplos provedores de LLMs (Google Gemini, Groq/LLaMA 3, OpenAI e instâncias locais via Ollama). O módulo consome as palavras-chave consensuais e os resumos mais representativos de cada *cluster*, sintetizando automaticamente títulos conceituais concisos e descrições contextuais acadêmicas.

A qualidade intrínseca das partições geradas é mensurada a partir de métricas formais recomendadas pela literatura (AMORIM et al., 2022):

- **Coerência Semântica (NPMI e C_V):** A métrica *Normalized Pointwise Mutual Information* avalia a coocorrência estatística de pares de termos (w_i, w_j) nos textos originais (RÖDER; BOTH; HINNEBURG, 2015):

$$\text{NPMI}(w_i, w_j) = \frac{\log \frac{P(w_i, w_j)}{P(w_i)P(w_j)}}{-\log P(w_i, w_j)} \quad (4.8)$$

O escore C_V combina o NPMI com a similaridade de cosseno calculada sobre janelas deslizantes de contexto vetorial.

- **Diversidade Temática via *Rank-Biased Overlap* Invertido (RBO):** Ao contrário da simples interseção de conjuntos, o algoritmo RBO (WEBBER; MOFFAT; ZOBEL, 2010) avalia a sobreposição ponderada pela posição hierárquica das palavras nos tópicos:

$$\text{RBO} = (1 - p) \sum_{d=1}^{d_{\max}} p^{d-1} A_d \quad (4.9)$$

em que A_d representa a proporção de concordância até a profundidade d , e o parâmetro $p \in (0, 1)$ penaliza fortemente modelos que replicam os mesmos termos no topo de múltiplos tópicos.

Em validações empíricas conduzidas sobre o acervo histórico da Revista de Informática Teórica e Aplicada (RITA – UFRGS), o *ensemble* proposto atingiu 66% de acurácia na classificação temática em relação às editoriais canônicas cadastradas pelo periódico, superando expressivamente o desempenho do LDA clássico, que obteve acurácia inferior a 45%.

4.3.4 Diagrama Estratégico de Callon e Dinâmica Temporal

Os tópicos consolidados são projetados no espaço bidimensional do Diagrama Estratégico de Callon (COBO et al., 2011), estruturado sobre a matriz de coocorrência ponderada pelo Índice de Equivalência (e_{ij}) entre pares de palavras-chave i e j :

$$e_{ij} = \frac{(c_{ij})^2}{c_i \times c_j} \quad (4.10)$$

sendo c_{ij} o número de artigos em que ambos os termos coocorrem e c_i, c_j as frequências isoladas de cada termo. A partir dessa formulação, o sistema calcula duas dimensões ortogonais:

- **Centralidade (C_k – Relevância Externa):** Mensura o grau de interação e interdependência de um tópico k com as demais comunidades da rede científica:

$$C_k = 10 \times \sum_{i \in k, j \notin k} e_{ij} \quad (4.11)$$

- **Densidade (D_k – Coesão Interna):** Mede a força associativa interna entre as palavras que compõem o tópico k , refletindo sua maturidade e capacidade de autorre-

gulação:

$$D_k = 100 \times \frac{\sum_{i,j \in k} e_{ij}}{N_k} \quad (4.12)$$

O sistema adota as medianas de centralidade e densidade como eixos divisores dinâmicos, distribuindo os tópicos em quatro quadrantes estratégicos: **Q1: Temas Motores** (alta centralidade e alta densidade; eixos estruturantes e maduros); **Q2: Temas Especializados** (baixa centralidade e alta densidade; tecnicamente desenvolvidos, porém isolados); **Q3: Temas Emergentes ou Decadentes** (baixa centralidade e baixa densidade; linhas marginais em estágio inicial ou em retração); e **Q4: Temas Básicos e Transversais** (alta centralidade e baixa densidade; conceitos amplos compartilhados por diversas subáreas).

Complementarmente, a evolução longitudinal é mapeada aplicando-se regressão linear sobre o volume de publicações anuais de cada tópico, extraindo o coeficiente angular de crescimento (β_{growth}) para classificar os eixos temáticos em expansão, estabilidade ou declínio.

4.3.5 Reuso Transversal, Persistência e Modo de Foco Global

Ao contrário de sistemas em que a modelagem temática encerra o fluxo analítico, na ferramenta desenvolvida a estratificação funciona como uma **camada semântica transversal**. A adição do atributo `unified_topic` ao conjunto de dados em memória habilita o reuso intermódulos:

1. **Segmentação no Dashboard Principal:** Desagrega as métricas cienciométricas (artigos, citações, índices h e g) por subárea temática específica;
2. **Redes Topológicas Segmentadas:** Recalcula dinamicamente matrizes de coautoria e acoplamento bibliográfico exclusivamente sobre a comunidade de interesse;
3. **Recomendação de Avaliadores (*Reviewer Matcher*):** Utiliza os descritores semânticos dos tópicos para mitigar conflitos de interesse e refinar o emparelhamento de manuscritos com pareceristas competentes;
4. **Persistência de Sessão e Modo de Foco (*Global Focus Mode*):** O sistema serializa e restaura o estado analítico completo em formato JSON (`clean_floats`), eliminando o custo computacional de reexecução. Além disso, a seleção de tópicos na interface propaga um filtro reativo global (`st.session_state.focus_topics`), fazendo com que todas as páginas do sistema operem instantaneamente sobre o subconjunto temático selecionado.

4.4 Mapeamento Científico e Redes Topológicas: Co-Citação, Acoplamento e Análise de Co-Palavras

A análise estrutural de redes no âmbito cienciométrico constitui um método fundamental para revelar a organização intelectual, as frentes emergentes de pesquisa e os chamados colégios invisíveis da ciência (DONTU et al., 2021). Por meio da modelagem em grafos, torna-se possível mapear relações latentes entre artigos, autores e conceitos. Nesta seção, são discutidas as limitações dos softwares tradicionais de visualização, as formulações matemáticas das três tipologias de redes implementadas, os algoritmos de particionamento e centralidade topológica, o método de desambiguação heurística de referências e a avaliação empírica de desempenho.

4.4.1 Limitações das Ferramentas Convencionais de Mapeamento

Embora consolidados, os softwares tradicionais de análise de redes bibliométricas impõem barreiras operacionais e cognitivas relevantes:

- **Visualizações estáticas e baixa interatividade no cliente:** Ferramentas como o VOSviewer (ECK; WALTMAN, 2010) utilizam algoritmos de posicionamento por similaridade (*VOS layout*), gerando representações estáticas ou de baixa manipulabilidade. O usuário não dispõe de recursos para reposicionar nós manualmente no navegador, isolar subgrafos sob demanda ou inspecionar dinamicamente atributos específicos sem reiniciar a projeção.
- **Sobrecarga de memória em execuções com matrizes densas:** Pacotes analíticos em R, a exemplo do *Bibliometrix* (ARIA; CUCCURULLO, 2017), realizam a construção de matrizes de adjacência e cálculos topológicos diretamente na memória da sessão local do R/Shiny. Em acervos que contêm milhares de referências cruzadas, a renderização gráfica frequentemente esgota a memória RAM (*Out-of-Memory*) e trava a interface do navegador.
- **Opacidade de identificadores bibliográficos abertos:** Bases modernas e abertas, como o OpenAlex (PRIEM; PIWOWAR; ORR, 2022), identificam obras por chaves alfanuméricas sintéticas (e.g., W2741809807) ou prefixos brutos de DOI. Softwares convencionais imprimem essas cadeias diretamente sobre os nós, tornando a visualização ilegível e forçando o pesquisador a consultar manualmente tabelas ex-

ternas para identificar os artigos correspondentes.

- **Rigidez na escolha de métricas e dimensionamento:** A maioria das soluções tradicionais vincula o tamanho visual dos vértices exclusivamente ao grau bruto de conexões (*degree*), ignorando que métricas alternativas de centralidade (como intermediação, autovetor ou PageRank) evidenciam papéis estruturais distintos na rede, como artigos de ponte interdisciplinar ou prestígio indireto (FREEMAN, 1978).

4.4.2 Modelagem Matemática das Tipologias de Rede

Para abranger as diferentes facetas da estrutura científica, o sistema constrói grafos não-direcionados e ponderados $G = (V, E, W)$ sobre a biblioteca *NetworkX*, implementando três perspectivas complementares de mapeamento:

1. **Rede de Co-Citação (*Co-citation Analysis*) (SMALL, 1973):** Quantifica a frequência com que duas referências históricas R_i e R_j são citadas conjuntamente na bibliografia de um mesmo artigo A_k da base analisada, evidenciando as bases conceituais do campo. O peso da aresta w_{ij}^{cocit} é expresso por:

$$w_{ij}^{\text{cocit}} = \sum_{k=1}^N \mathbb{I}(R_i \in \text{Refs}(A_k) \wedge R_j \in \text{Refs}(A_k)) \quad (4.13)$$

onde $\mathbb{I}(\cdot)$ representa a função indicadora e $\text{Refs}(A_k)$ o conjunto de referências do artigo A_k . O cálculo é otimizado em memória por meio de combinações pareadas vetorizadas (`itertools.combinations`) sobre listas limpas de referências.

2. **Rede de Acoplamento Bibliográfico (*Bibliographic Coupling*) (KESSLER, 1963):** Conecta dois manuscritos correntes A_i e A_j pertencentes ao acervo caso compartilhem uma ou mais citações em suas listas bibliográficas, mapeando as frentes ativas de pesquisa. O peso da aresta w_{ij}^{coup} é determinado pela cardinalidade da interseção entre seus conjuntos de referências:

$$w_{ij}^{\text{coup}} = |\text{Refs}(A_i) \cap \text{Refs}(A_j)| \quad (4.14)$$

O algoritmo opera através de operações nativas de conjuntos em Python (`refs1 & refs2`), gerando a matriz de adjacência de forma eficiente.

3. **Rede de Coocorrência de Palavras (*Co-Word Analysis*) (CALLON et al., 1983):**

Constrói uma rede ego em torno de um termo focal selecionado (*Focus Word*). A rotina sanitiza os campos de texto (título, resumo e palavras-chave), elimina *stopwords* via NLTK e mapeia os N termos mais fortemente associados ao termo central, ponderando os vínculos pelo volume de coocorrências conjuntas.

4.4.3 Desambiguação Heurística e Detecção de Comunidades

Para solucionar a opacidade de referências brutas sem onerar a memória do sistema, implementou-se a rotina de desambiguação `format_ref_label`. O algoritmo realiza um cruzamento hierárquico em memória:

- Se o identificador for um DOI válido (10 . xxx), busca correspondência no acervo carregado e formata o rótulo como “*Sobrenome (Ano) - Título...*”;
- Se o identificador for uma chave OpenAlex (w . . .), localiza o metadado correspondente na base;
- Caso a obra pertença à literatura externa não contida no acervo mestre, o rótulo é truncado de forma legível (e.g., “*DOI: 10.1016/...*”), prevenindo a inserção de sequências alfanuméricas desproporcionais que degradem a estética do grafo.

O particionamento estrutural dos nós em comunidades temáticas coesas fundamenta-se na otimização da **Modularidade de Louvain** (Q) (BLONDEL et al., 2008):

$$Q = \frac{1}{2m} \sum_{i,j} \left[A_{ij} - \frac{k_i k_j}{2m} \right] \delta(c_i, c_j) \quad (4.15)$$

onde A_{ij} expressa o peso da aresta entre os nós i e j , $k_i = \sum_j A_{ij}$ denota a soma dos pesos incidentes no nó i , $m = \frac{1}{2} \sum_{i,j} A_{ij}$ corresponde à massa total de arestas da rede, c_i indica a comunidade do vértice i , e $\delta(c_i, c_j)$ é o delta de Kronecker (que assume valor 1 se $c_i = c_j$, e 0 caso contrário). Para assegurar tolerância a falhas, o sistema dispõe de rotinas de contingência por Modularidade Gulosa (*Greedy Modularity*) e Propagação de Rótulos (*Label Propagation*).

4.4.4 Centralidades Topológicas, Renderização Interativa e Exportação

Para permitir uma análise estrutural facetada, o sistema calcula de forma vetorizada cinco métricas clássicas de centralidade sobre o grafo ponderado (FREEMAN, 1978):

- **Grau Ponderado (*Degree Centrality*):** $C_D(i) = \sum_{j \in V} A_{ij}$, quantificando a força total de conexões imediatas do nó;
- **Intermediação (*Betweenness Centrality*) (BRANDES, 2001):** $C_B(i) = \sum_{s \neq i \neq t} \frac{\sigma_{st}(i)}{\sigma_{st}}$, identificando nós estratégicos que atuam como pontes informacionais ao longo dos caminhos geodésicos;
- **Autovetor (*Eigenvector Centrality*):** $\lambda x_i = \sum_{j \in V} A_{ij} x_j$, ponderando o prestígio de um nó pela relevância de seus vizinhos adjacentes, com captura explícita de exceções para tratar eventuais falhas de convergência numérica;
- **Proximidade (*Closeness Centrality*):** $C_C(i) = \frac{|V|-1}{\sum_{j \neq i} d(i,j)}$, mensurando a velocidade média de propagação para todos os demais nós;
- **PageRank (PAGE et al., 1999):** Determina a autoridade acadêmica recursiva do nó com base em caminhadas aleatórias com fator de amortecimento configurado em $d = 0,85$.

O raio visual de cada vértice é dimensionado dinamicamente no intervalo de 15px a 55px a partir do escore normalizado $\hat{v}_i = \frac{v_i}{\max(V)}$, acoplado a uma interpolação linear RGB que projeta um gradiente visual contínuo do azul celeste (`rgb(147, 197, 253)`) ao azul real profundo (`rgb(37, 99, 235)`).

A renderização gráfica é realizada pela biblioteca *Pyvis* integrada ao Streamlit via componentes HTML5. A simulação conta com física de forças contínuas (*force-directed physics*), permitindo zoom, movimentação livre de vértices e inspeção de metadados sob cursor (*hover tooltips*). O módulo disponibiliza tabelas com os 20 principais pares de maior associação, legendas estruturadas por *cluster* e botões de exportação direta do arquivo HTML autocontido e das matrizes em formato CSV.

4.5 Evolução Temporal e Fluxo Temático: Fatiamento Dinâmico, NMF e Diagrama de Sankey

O mapeamento longitudinal da ciência visa compreender a dinâmica evolutiva de um domínio do conhecimento ao longo do tempo, identificando padrões de continuidade, emergência, fusão (*merging*), ramificação (*splitting*) e obsolescência de conceitos teóricos (CHEN, 2006; COBO et al., 2012). Diferentemente de análises transversais estáticas, o estudo longitudinal reconstrói as linhagens conceituais que moldaram a história de um periódico ou campo de pesquisa. Nesta seção, são discutidas as limitações das ferramentas legadas, as estratégias de fatiamento temporal e fatoração matricial por época, o algoritmo de rastreamento de linhagens conceituais e a modelagem visual do Diagrama de Sankey.

4.5.1 Limitações das Abordagens Temporais Convencionais

As metodologias tradicionais de análise temporal em cienciometria impõem restrições de usabilidade e distorções estatísticas que dificultam o diagnóstico editorial:

- **Rigidez no fatiamento por calendários arbitrários:** Ferramentas clássicas como o SciMAT (COBO et al., 2012) e o CiteSpace (CHEN, 2006) exigem que o pesquisador defina períodos rígidos baseados em décadas ou anos fixos (e.g., 2000–2010, 2011–2020). Em domínios caracterizados por crescimento exponencial de publicações, essa divisão manual gera fatias iniciais escassas e épocas recentes superlotadas, comprometendo a representatividade amostral dos modelos.
- **Saturação visual e sobreposição em grafos (*spaghetti graphs*):** O CiteSpace costuma gerar redes temporais densas que sofrem com forte sobreposição de nós e arestas, exigindo parametrizações manuais complexas para tornar a visualização inteligível.
- **Ausência de linhagens de transmissão conceitual:** Softwares como VOSviewer e Bibliometrix (ARIA; CUCCURULLO, 2017) tratam a dimensão temporal aplicando sobreposições de cores (*time overlays*) sobre grafos estáticos de coocorrência. Embora evidenciem a idade média dos termos, esses gradientes cromáticos não explicitam a árvore genealógica dos temas, impedindo a visualização direta de como tópicos históricos deram origem a subáreas contemporâneas.
- **Opacidade e custo computacional de modelos contínuos:** Modelos probabilísti-

cos contínuos de tópicos no tempo (*Dynamic Topic Models – DTM*) (BLEI, 2012) demandam alto custo de processamento e operam como caixas-pretas de difícil tradução gráfica direta para fluxos de decisão editorial.

4.5.2 Estratégias de Fatiamento Temporal e Fatoração Local via NMF

Para superar a rigidez de calendários fixos, o módulo de Fluxo Temático (`features/thematic_`) implementa três estratégias configuráveis de segmentação temporal:

1. **Volume Documental Balanceado (*Balanced Volume*):** Emprega quantis empíricos (`pd.qcut`) sobre a distribuição de anos válidos, particionando o acervo de modo que cada época contenha uma quantidade uniforme de artigos, neutralizando distorções decorrentes do crescimento exponencial da literatura;
2. **Intervalos Cronológicos Iguais (*Equal Intervals*):** Divide a amplitude histórica total em janelas de extensão temporal homogênea;
3. **Marcos Customizados (*Custom Cutoffs*):** Permite ao analista definir anos específicos de transição, correspondentes a mudanças de escopo editorial, reformas curriculares ou marcos metodológicos do periódico.

É fundamental ressaltar a distinção metodológica entre a **Estratificação Temática Global** (apresentada na Seção 4.3) e o **Fluxo Temático Temporal**. Enquanto a modelagem global avalia o acervo integralmente para extrair macro-tópicos transversais e contínuos, o fluxo temático particiona a linha do tempo em eras independentes ($E_1, E_2, \dots, E_T$). Dentro de cada época, os textos são faturados de forma autônoma a fim de capturar a microestrutura e o vocabulário específicos daquele período histórico.

Em cada era E_t , o texto unificado (título, resumo e palavras-chave) é pré-processado com remoção de termos acadêmicos genéricos em português e inglês (*stopwords*) e convertido em uma matriz termo-documento ponderada por TF-IDF $V \in \mathbb{R}_+^{D \times M}$. A extração dos tópicos locais é executada pela **Fatoração de Matrizes Não-Negativas** (NMF) (LEE; SEUNG, 1999), resolvida sob a inicialização determinística NNDSVDa:

$$\min_{W \geq 0, H \geq 0} \frac{1}{2} \|V - WH\|_F^2 \quad (4.16)$$

onde $W \in \mathbb{R}_+^{D \times K}$ expressa a matriz de pertinência documento-tópico e $H \in \mathbb{R}_+^{K \times M}$ contém os coeficientes dos termos por componente.

Para evitar a sub ou a super-segmentação em períodos com densidades variáveis, o número de tópicos K de cada era é ajustado dinamicamente por uma heurística adaptativa baseada no volume de documentos (N_{era}):

$$K = \max(3, \min(12, \lfloor N_{\text{era}}/35 \rfloor)) \quad (4.17)$$

Os termos mais representativos de cada tópico correspondem aos 15 maiores coeficientes na respectiva linha da matriz H , enquanto a alocação do documento ao tópico predominante dá-se pelo índice de maior peso em W .

4.5.3 Rastreamento Longitudinal de Linhagens e Diagrama de Sankey

Como a fatoração NMF é executada isoladamente em cada fatia temporal, os tópicos de épocas distintas não compartilham identificadores prévios. Para construir a linhagem histórica de transmissão de conhecimento entre a Era E_t e a Era subsequente E_{t+1} , o sistema calcula a sobreposição semântica entre os conjuntos de palavras-chave $A = \text{TopWords}(T_{t,i})$ e $B = \text{TopWords}(T_{t+1,j})$ utilizando o **Coefficiente de Similaridade de Jaccard** (JACCARD, 1901):

$$J(A, B) = \frac{|A \cap B|}{|A \cup B|} \quad (4.18)$$

Sempre que a concordância atinge um limiar mínimo configurável na interface ($J(A, B) \geq \tau_{\text{sim}}$), estabelece-se uma aresta orientada de herança conceitual entre os tópicos ($T_{t,i} \rightarrow T_{t+1,j}$).

A projeção visual das trajetórias consolidadas é representada por meio de um **Diagrama de Sankey** interativo compilado via Plotly. A largura de cada fita conectora reflete a intensidade da similaridade combinada ao volume de publicações que sustentam o tema de origem:

$$\text{Valor do Fluxo} = \max(1, \lfloor J(A, B) \times N_{\text{docs}}(T_{t,i}) \times 10 \rfloor) \quad (4.19)$$

Essa formulação viabiliza o reconhecimento visual imediato dos quatro fenômenos clássicos da evolução científica:

- **Fusão (Merging):** Convergência de múltiplos fluxos de uma era para um único

tópico estruturado na era seguinte;

- **Ramificação (*Splitting*):** Fragmentação de uma temática ampla em duas ou mais subáreas especializadas;
- **Continuidade Estável:** Manutenção de fitas paralelas e contínuas ao longo de múltiplas eras sucessivas;
- **Obsolescência ou Declínio:** Tópicos que deixam de projetar conexões para as épocas seguintes, evidenciando o encerramento ou esgotamento de linhas de pesquisa.

Os nós do diagrama são renderizados em paleta de tons pastel com transparências RGBA direcionadas, incorporando *tooltips* contextuais que exibem, ao passar do cursor, a contagem de artigos e as sete palavras-chave mais distintivas de cada tema.

4.6 Indicadores de Governança Editorial e Auditoria de Endogenia Institucional

A manutenção e a indexação de periódicos acadêmicos em indexadores internacionais de alto impacto (como SciELO, Scopus e Web of Science) estão estritamente vinculadas à observância de diretrizes éticas e à autonomia de seus conselhos editoriais (NAZAROVETS; NAZAROVETS, 2025; MARZIALE, 2014). Entre os critérios avaliados, a **Endogenia Institucional** — caracterizada pela publicação desproporcional de manuscritos vinculados à própria instituição mantenedora da revista — constitui o principal fator de risco para o isolamento científico e o cancelamento de indexações (STUMPF, 1996; PINTO et al., 2024). Nesta seção, discutem-se as lacunas dos softwares bibliométricos no suporte à gestão de periódicos, a formalização matemática do índice de endogenia, as rotinas de higienização amostral e a implementação do painel de conformidade regulatória.

4.6.1 Relevância Regulatória e Limitações das Abordagens Manuais

O ecossistema tradicional de softwares cienciométricos apresenta uma lacuna conceitual marcante quanto às necessidades dos corpos editoriais:

- **Foco exclusivo no consumo da literatura:** Ferramentas como VOSviewer, Bibliometrix, CiteSpace e SciMAT (MORAL-MUNOZ et al., 2020) foram projetadas sob a perspectiva do pesquisador que consome dados científicos. Consequentemente,

nenhuma dessas soluções oferece recursos nativos para auditoria de comitês editoriais, controle de proveniência institucional ou monitoramento de parâmetros éticos de publicação.

- **Processamento manual suscetível a erros amostrais:** Na prática editorial, a verificação de conformidade costuma ser realizada manualmente por equipes de secretaria por meio de planilhas eletrônicas. Esse processo é altamente propenso a inconsistências, tais como a omissão de coautorias secundárias em artigos com múltiplos autores e a falha em identificar grafias variantes de uma mesma universidade.
- **Subestimação artificial por opacidade de metadados:** Softwares genéricos raramente quantificam o percentual de artigos que não possuem dados de afiliação cadastrados. Ao processar registros incompletos como “não-endógenos”, essas abordagens geram taxas artificialmente reduzidas, conferindo uma falsa percepção de conformidade com as agências regulatórias.

4.6.2 Formalização Matemática do Índice e Higienização Amostral

Para conferir rigor metodológico e repetibilidade ao cálculo, o módulo de governança (`dashboard/governance.py`) formaliza o **Índice de Endogenia Institucional** (E_{inst}) a partir de operações booleanas sobre conjuntos de afiliação (SciELO, 2020).

Seja N_{total} o volume total de publicações submetidas à análise. O sistema executa inicialmente uma rotina determinística de auditoria de qualidade amostral, identificando e segregando os artigos desprovidos de metadados válidos de filiação (`isna`, cadeias vazias ou termos nulos). O cálculo restringe-se estritamente ao conjunto de artigos válidos $A = N_{\text{total}} - N_{\text{missing}}$, reportando visualmente o percentual de exclusão para assegurar a transparência estatística.

Para cada artigo válido $a \in \{1, 2, \dots, A\}$, define-se $I_a = \{i_{a,1}, i_{a,2}, \dots, i_{a,k}\}$ como o conjunto de todas as instituições declaradas por seus coautores. Denotando por I_{pub} a instituição mantenedora ou editora do periódico, a função indicadora booleana de endogenia $\delta(I_a, I_{\text{pub}})$ é expressa por:

$$\delta(I_a, I_{\text{pub}}) = \begin{cases} 1, & \text{se } I_a \cap I_{\text{pub}} \neq \emptyset \\ 0, & \text{se } I_a \cap I_{\text{pub}} = \emptyset \end{cases} \quad (4.20)$$

A taxa percentual de endogenia institucional (E_{inst}) do acervo é então formulada

como:

$$E_{\text{inst}} = \left(\frac{\sum_{a=1}^A \delta(I_a, I_{\text{pub}})}{A} \right) \times 100 \quad (4.21)$$

A extração das instituições apoia-se em um analisador heurístico que padroniza múltiplos delimitadores (vírgulas e pontos-e-vírgulas), gerando uma lista ordenada de entidades únicas (`unique_affiliations`). Esse catálogo alimenta um componente interativo de seleção na interface, que permite ao editor escolher a instituição mantenedora ou fornecer termos de busca customizados em caixa baixa, garantindo que variações textuais menores sejam contempladas na interseção booleana.

4.6.3 Painel de Auditoria Forense e Alertas Regulatórios

Para além do cômputo quantitativo, o módulo funciona como uma ferramenta ativa de tomada de decisão, incorporando mecanismos de alerta alinhados às diretrizes do *Committee on Publication Ethics* (COPE) e de indexadores como o SciELO (SciELO, 2020).

O usuário pode parametrizar o teto regulatório tolerado ($\text{Threshold}_{\text{reg}}$) por meio de um controle deslizante na interface (com valor padrão fixado em 20%, limite clássico estabelecido pelo SciELO Brasil). O sistema calcula instantaneamente a margem de segurança regulatória:

$$\Delta_{\text{reg}} = \text{Threshold}_{\text{reg}} - E_{\text{inst}} \quad (4.22)$$

A partir do valor de Δ_{reg} , o sistema dispara avisos semafóricos contextuais:

- **Conformidade (*Compliant*):** Quando $E_{\text{inst}} \leq \text{Threshold}_{\text{reg}}$, indicando que o periódico opera dentro dos parâmetros de diversidade institucional exigidos;
- **Alerta de Risco (*Non-Compliance Alert*):** Quando $E_{\text{inst}} > \text{Threshold}_{\text{reg}}$, emitindo uma sinalização de risco iminente de desindexação e indicando o percentual de excesso que deve ser mitigado nos próximos volumes.

O painel é complementado por uma tabela forense detalhada que lista exclusivamente os manuscritos classificados como endógenos. A tabela expõe o título da obra, a lista completa de autores, o ano de publicação, o conjunto integral de afiliações identificadas e o respectivo identificador persistente (DOI), fornecendo aos editores as evidências documentais necessárias para auditorias de conformidade e planejamento de chamadas de trabalhos futuras.

4.7 Mapeamento Geográfico Global e Redes de Coautoria Transnacional

A capilaridade geográfica e a intensidade da colaboração transnacional são métricas indispensáveis para aferir o grau de internacionalização, a inserção global e a diversidade demográfica de periódicos e comunidades científicas (DONTHU et al., 2021; TRUONG; NGUYEN-DUC; VAN, 2023). Contudo, a extração de dados espaciais a partir de bases bibliográficas enfrenta desafios severos de qualidade de dados decorrentes da falta de padronização nas declarações de filiação institucional. Nesta seção, são analisados os gargalos e as fontes de ruído nos metadados espaciais, a arquitetura híbrida de desambiguação geográfica, a modelagem probabilística de inferência demográfica, a construção do grafo de coautoria transnacional e a avaliação empírica da solução.

4.7.1 Gargalos em Metadados Espaciais e Limitações das Ferramentas Vigentes

A análise espacial na cienciometria computacional esbarra frequentemente na desestruturação dos campos de filiação exportados por bases como Scopus, Web of Science e PubMed (MINUZZO et al., 2026):

- **Heterogeneidade léxica e ausência de padronização:** Declarações de afiliação consistem tipicamente em texto livre não estruturado (e.g., “*Dept. of Computer Science, Univ. of Sao Paulo, SP, Brazil*” ou “*Univ. Paris-Saclay, Gif-sur-Yvette, France*”). A coexistência de nomes em línguas nativas (*Deutschland, España, Nippon*), acrônimos institucionais e variações tipográficas impede a agregação direta por país sem pré-processamento.
- **Falsos positivos em correspondências ingênuas de texto:** Algoritmos simples baseados em busca por subcadeia (*substring matching*) ou correspondência direta de códigos ISO de dois caracteres introduzem severas distorções documentadas na literatura cienciométrica (SANTAMARÍA; MIHALJEVIĆ, 2018; MINUZZO et al., 2026). Por exemplo:
 1. A busca pela sigla US (Estados Unidos) sem controle de fronteira de palavra captura falsos positivos no interior de termos como *Australia, Russia, Discussion* ou *Campus*;
 2. O código ISO IN (Índia) colide frequentemente com o termo funcional *Institute* ou com a preposição em língua inglesa “*in*”;

3. A busca pelo país *Oman* gera correspondências espúrias em nomes próprios e termos contextuais como *Woman* ou *Roman*.
- **Dependência de ferramentas externas de geoprocessamento (SIG):** Softwares bibliométricos concorrentes, como VOSviewer e Bibliometrix (ARIA; CUCCURULLO, 2017), não integram módulos cartográficos interativos. Para gerar mapas de calor coropléticos, o pesquisador é forçado a exportar tabelas e operar Sistemas de Informação Geográfica externos (como QGIS ou ArcGIS), exigindo manipulação manual de arquivos vetoriais (*shapefiles*).
 - **Saturação visual em grafos de colaboração:** Redes de cooperação internacional costumam ser apresentadas como matrizes densas e sobrecarregadas, sem filtros dinâmicos de corte (*Top-N*) ou ajustes na escala dos vértices, permitindo que países hiperprodutivos ocluam visualmente nações emergentes.

4.7.2 Arquitetura de Desambiguação Espacial em Duas Camadas

Para mitigar tais fragilidades e garantir precisão na atribuição geográfica, o módulo (`features/demographics.py`) implementa um mecanismo híbrido estruturado em dois níveis complementares:

- **Camada 1 – Identificação Canônica via OpenAlex e ROR:** Consome os identificadores persistentes do *Research Organization Registry* (ROR) integrados à API do OpenAlex (PRIEM; PIWOWAR; ORR, 2022), mapeando diretamente as afiliações normalizadas para códigos canônicos de país (ISO Alpha-2).
- **Camada 2 – Analisador Heurístico com Limites de Fronteira (`extract_countries`):** Atua como *fallback* para bases locais ou registros sem identificador ROR. O algoritmo opera sobre um dicionário multilíngue (`COUNTRY_MAPPING`) contendo mais de 60 nações, cobrindo grafias em idiomas nativos, formas formais e acrônimos globais. Para eliminar colisões com substrings internas, o mecanismo compila dinamicamente expressões regulares com limites estritos de fronteira de palavra (`\b`):

$$\text{Padrão} = \backslash b + \text{chave_pais} + \backslash b \quad (4.23)$$

Essa formulação assegura que a entidade seja reconhecida unicamente como uma palavra isolada e completa na sentença.

Antes da geração gráfica, o sistema executa uma auditoria de integridade espacial, quantificando o percentual de artigos que carecem de dados geográficos válidos. O cálculo subsequente opera estritamente sobre a amostra consistente, prevenindo conclusões enviesadas sobre a taxa de internacionalização.

4.7.3 Inferência Demográfica de Gênero e Auditoria de Representatividade

A análise de governança e diversidade demográfica inclui a inferência algorítmica de gênero dos primeiros autores, fundamentada nas diretrizes metodológicas de Minuzzo et al. (2026). O sistema utiliza um modelo probabilístico tripartite calibrado por um limiar de decisão estrito ($\tau = 0,75$):

$$\text{Classe}(\textit{nome}) = \begin{cases} \text{Feminino}, & \text{se } P(\text{feminino} \mid \textit{nome}) \geq \tau \\ \text{Masculino}, & \text{se } P(\text{masculino} \mid \textit{nome}) \geq \tau \\ \text{Indefinido}, & \text{se } \max(P(g \mid \textit{nome})) < \tau \text{ ou prenome ausente} \end{cases} \quad (4.24)$$

A adoção da classe *Indefinido* é um requisito ético e metodológico central. Conforme demonstrado por Santamaría and Mihaljević (2018), classificadores de prenomes apresentam vieses sistemáticos contra nomes não-ocidentais, além de enfrentarem limitações inerentes de transliteração em escritas não-latinas (como mandarim ou árabe) e a impossibilidade de capturar identidades de gênero não-binárias (HOLMAN; STUART-FOX; HAUSER, 2018). Dessa forma, a inferência é empregada exclusivamente para fins de auditoria estatística agregada de representatividade histórica no periódico.

4.7.4 Visualização Coroplética e Grafo de Coautoria Transnacional

Os metadados normalizados alimentam simultaneamente dois componentes analíticos integrados:

1. **Mapa Coroplético Global Interativo:** Compilado via Plotly Express (`px.choropleth`) diretamente no navegador web, projetando o volume de produção científica por nação sobre escalas contínuas de cores, com suporte a ampliação (*zoom*) e inspeção detalhada por meio de caixas de contexto (*tooltips*).
2. **Grafo de Coautoria Transnacional** $G = (V, E, W)$: Modela a cooperação inter-

nacional como uma rede não-direcionada ponderada, onde V representa os países e E expressa as parcerias intercontinentais.

Para cada manuscrito a com autores afiliados a múltiplos países distintos ($C_a \subseteq V$), o peso da aresta w_{ij} que une as nações i e j ($i \neq j$) é incrementado cumulativamente (DONTU et al., 2021):

$$w_{ij} = \sum_{a=1}^A \mathbb{I}(i \in C_a \wedge j \in C_a) \quad (4.25)$$

sendo $\mathbb{I}(\cdot)$ a função indicadora de coautoria multinacional. A produção científica isolada de um país corresponde a $S_i = \sum_{a=1}^A \mathbb{I}(i \in C_a)$.

Para evitar que potências científicas de alta densidade publiquem volumes que resultem em nós gigantescos cobrindo vértices menores, o diâmetro visual do nó R_i é modulado por uma transformação sublinear baseada em raiz quadrada:

$$R_i = 10 + 2 \times \sqrt{S_i} \quad (4.26)$$

O posicionamento espacial dos vértices no plano bidimensional é computado pelo algoritmo de forças elásticas de Fruchterman-Reingold (*Spring Layout*) (FRUCHTERMAN; REINGOLD, 1991), agrupando organicamente blocos regionais de cooperação (e.g., União Europeia, América Latina). O módulo disponibiliza filtros interativos de corte (*Top-N*) para isolar as nações de maior conectividade.

4.8 Assistente de Triagem PRISMA para Revisões e Mapeamentos Sistemáticos da Literatura

A realização de Revisões Sistemáticas da Literatura (RSL) e Estudos de Mapeamento Sistemático (SMS) na Engenharia de Software e na Ciência da Computação exige estrita conformidade com protocolos formais de identificação, seleção e descarte de evidências primárias (KITCHENHAM et al., 2009; PETERSEN et al., 2008; PETERSEN; VAKKALANKA; KUZNIARZ, 2015). O relato transparente desse processo é normatizado pela declaração internacional PRISMA 2020 (*Preferred Reporting Items for Systematic Reviews and Meta-Analyses*) (PAGE et al., 2021). Nesta seção, discutem-se as limitações dos ambientes tradicionais de triagem, a concepção da máquina de estados do módulo PRISMA Assistant, a geração determinística do diagrama de fluxo e a

propagação reativa do *corpus* elegível para a suíte cienciométrica.

4.8.1 Gargalos Metodológicos em Protocolos de RSL e Limitações Concorrentes

O fluxo metodológico de seleção amostral enfrenta entraves operacionais e conceituais decorrentes da fragmentação das ferramentas disponíveis:

- **Desconexão entre softwares cienciométricos e protocolos de RSL:** Soluções consolidadas como VOSviewer, Bibliometrix e CiteSpace (ARIA; CUCCURULLO, 2017; MORAL-MUNOZ et al., 2020) operam sob a premissa de que o conjunto de dados inserido já passou por todas as fases de elegibilidade. Tais ferramentas desconsideram o rastreamento das etapas prévias de descarte e a contagem discriminada de duplicatas.
- **Silos fechados e quebra de proveniência em plataformas dedicadas:** Ambientes específicos de triagem (como Rayyan, Covidence ou Parsifal) funcionam em silos proprietários. O pesquisador é obrigado a exportar arquivos intermediários, efetuar a triagem em uma interface isolada e reimportar os dados aceitos para os softwares de análise, perdendo o vínculo de rastreabilidade com o enriquecimento de metadados e as análises temáticas.
- **Inconsistências numéricas em diagramas manuais:** Na prática acadêmica, a elaboração do fluxograma PRISMA costuma ser realizada manualmente em editores gráficos genéricos (como PowerPoint ou Canva). Esse procedimento introduz frequentes divergências aritméticas entre o total bruto de registros importados de múltiplas bases, as duplicatas eliminadas e os motivos formais de exclusão registrados.
- **Ausência de reatividade no espaço de trabalho:** Em sistemas convencionais, a eliminação de um artigo durante a etapa de leitura integral não propaga a alteração automaticamente para os demais módulos, exigindo o recálculo manual de matrizes de coautoria, tópicos e grafos de citação.

4.8.2 Máquina de Estados de Triagem e Fila Interativa (Critérios PICOC)

Para integrar a esteira de ingestão ao fluxo de elegibilidade de forma contínua, o módulo (`features/prisma_assistant.py`) implementa uma máquina de estados finitos persistida no escopo da sessão (`st.session_state.prisma_state`).

O sistema rastreia o montante bruto de registros carregados em múltiplos arquivos durante a etapa de ingestão (N_{imported}) e calcula automaticamente as duplicatas expurgadas na camada de normalização ($N_{\text{duplicates}}$) ao contrastar as entradas brutas com o acervo único deduplicado (D_{raw}):

$$N_{\text{duplicates}} = N_{\text{imported}} - |D_{\text{raw}}| \quad (4.27)$$

A triagem inicial ocorre por meio de uma fila dinâmica estruturada em cartões contextuais de decisão. Cada cartão exibe os metadados bibliográficos essenciais (título, autores, ano, periódico/evento, tipo de documento e palavras-chave) acompanhados do texto completo do resumo em bloco expansível.

Para cada registro sob avaliação, o pesquisador pode acionar uma de três ações fundamentais:

1. **Incluir (*Include*):** O artigo é validado e transferido da fila de espera (`screening_queue`) para o rol de estudos aceitos (`screened_ok`);
2. **Excluir (*Exclude*):** O identificador do manuscrito é registrado em uma estrutura de exclusões associado a uma justificativa formal parametrizável alinhada aos critérios do protocolo PICOC (*Population, Intervention, Comparison, Outcome, Context*) (KITCHENHAM et al., 2009), como *Fora do Escopo (Off-topic)*, *Idioma Incompatível (Wrong Language)*, *Sem Revisão por Pares (Not Peer-Reviewed)* ou categorias personalizadas pelo usuário;
3. **Postergar (*Skip*):** O manuscrito é realocado temporariamente para o final da fila sem decisão conclusiva imediata.

4.8.3 Compilação do Diagrama PRISMA 2020 e Propagação Reativa

As contagens consolidadas pela máquina de estados alimentam dinamicamente a geração do fluxograma oficial PRISMA 2020. O balanço amostral do protocolo obedece às relações formais de conservação de fluxo:

$$N_{\text{screened}} = |D_{\text{raw}}|, \quad N_{\text{excluded}} = |\text{exclusions}|, \quad N_{\text{included}} = N_{\text{screened}} - N_{\text{excluded}} \quad (4.28)$$

A partir dessas métricas e da agregação quantitativa de cada justificativa de descarte, o sistema compila em tempo real um grafo direcionado expresso em linguagem

DOT, renderizado na interface gráfica através do Graphviz:

- **Alinhamento Hierárquico (`{rank=same}`):** Garante que os nós correspondentes aos estágios longitudinais (*Identificação*, *Triagem* e *Inclusão*) fiquem nivelados horizontalmente às suas respectivas caixas laterais de exclusão;
- **Semiótica Visual Padronizada:** O avanço do *corpus* principal é representado por arestas sólidas e caixas informativas, enquanto ramificações de descarte utilizam arestas tracejadas (`style=dashed`) conectadas a caixas de destaque em tons pastéis avermelhados (`fillcolor="#FEE2E2"`), culminando no nó terminal de inclusão em tom verde suave (`fillcolor="#DCFCE7"`);
- **Exportabilidade e Ajuste Manual:** O sistema disponibiliza campos para refinamento manual de contagens externas e permite o download do código-fonte em formato `.dot`, facilitando a diagramação vetorial para publicação.

Para preservar a integridade dos dados durante a execução, o sistema mantém uma cópia do conjunto deduplicado original (`raw_df_backup`). Concluída a etapa de leitura, o acionamento do comando de confirmação (*Commit Final Included Dataset*) atualiza atômica e o conjunto mestre de trabalho (`master_df`), expurgando os índices rejeitados. Essa sincronização propaga instantaneamente o *corpus* estritamente elegível para todos os demais módulos do sistema — incluindo a estratificação temática, o mapeamento de Callon, as redes topológicas e a governança editorial —, assegurando a reprodutibilidade metodológica da pesquisa.

4.9 Mapeamento Demográfico de Diversidade de Gênero

4.10 Recomendação de Parcerias (*Reviewer Matcher*)

5 ESTUDO DE CASO E VALIDAÇÃO EXPERIMENTAL

Para avaliar a aplicabilidade prática, a robustez e o ganho computacional da plataforma desenvolvida, conduziu-se um estudo de caso experimental sobre o acervo histórico da **Revista de Informática Teórica e Aplicada (RITA)**, periódico científico mantido pelo Instituto de Informática da Universidade Federal do Rio Grande do Sul (UFRGS).

Neste capítulo, são apresentados a caracterização da base de dados utilizada, os testes de desempenho da camada de ingestão e enriquecimento, a análise cienciométrica e de integridade do periódico, a validação da modelagem temática via *ensemble* de PLN, a evolução longitudinal de tópicos e a auditoria de conformidade regulatória.

5.1 Caracterização do Acervo Experimental (Revista RITA)

A RITA publica pesquisas originais nos diversos ramos da Ciência da Computação e Engenharia de Software desde o início da década de 1990. Os metadados brutos do periódico foram exportados a partir de planilhas de gestão editorial e arquivos tabulares, apresentando desafios típicos de bases históricas: variações de codificação de caracteres (Latin-1 *versus* UTF-8), ausência de identificadores digitais (DOIs) em edições anteriores aos anos 2000, resumos truncados e despadronização nas strings de afiliação institucional.

5.2 Avaliação de Desempenho do Duto de Ingestão e Enriquecimento

A camada de ingestão foi submetida a testes com conjuntos heterogêneos de arquivos malformados, incluindo CSVs com delimitadores mistos (vírgulas e pontos-e-vírgulas coexistentes) e quebras de linha espúrias em resumos. O analisador heurístico (`parse_file`) alcançou taxa de sucesso de 100% na recuperação dos registros sem interrupções de execução (*crashes*), identificando automaticamente as tabelas de codificação e aplicando preenchimento horizontal (*backward fill*) para colunas homônimas.

No enriquecimento de metadados, comparou-se a abordagem legada síncrona (baseada exclusivamente em consultas unitárias à API do Crossref) com o pipeline em cinco níveis implementado (*Multi-Tier Enrichment*), que prioriza requisições em lote de 50 itens via OpenAlex sob regime de *Polite Pool* e *cache* persistente em disco.

Em um teste de estresse conduzido com um lote amostral expandido de 10.000

artigos acadêmicos:

- O motor síncrono convencional demandou mais de **120 minutos** de execução, sofrendo frequentes interrupções por bloqueios de taxa (*rate limiting*);
- O pipeline desenvolvido concluiu o processamento completo em **26 minutos e 40 segundos**, representando um ganho de velocidade superior a $4,5\times$ em primeira execução e superando $15\times$ quando acionada a camada de *cache* local.

Além do ganho temporal, a recuperação de dados em artigos históricos sem DOI (Tier 5 – *Fuzzy Title Search*) permitiu resgatar resumos e afiliações para mais de 78% dos artigos antigos da RITA que antes eram desconsiderados por ferramentas tradicionais.

5.3 Análise Cienciométrica e Diagnóstico de Integridade

A aplicação do painel principal sobre o acervo da RITA permitiu traçar o perfil de produtividade do periódico e qualificar a integridade dos metadados. O módulo de diagnóstico de qualidade identificou de forma transparente que 94% dos registros contavam com autoria e ano consolidados após o enriquecimento, isolando os 6% de registros incompletos para auditoria visual e exportação seletiva.

Na avaliação do impacto citatório, a integração simultânea do Índice-*h* clássico e do Índice-*g* de Egghe evidenciou artigos de alto impacto acumulado (*blockbusters*) publicados na revista que não recebiam destaque proporcional no *h*-index convencional.

Para diagnosticar o grau de concentração de impacto, o sistema calculou o Coeficiente de Gini (*G*) sobre a distribuição de citações dos artigos da revista, confrontando a Curva de Lorenz gerada com a Reta de Perfeita Igualdade (Equações 4.3 e 4.4).

5.4 Estratificação Temática e Validação do Ensemble de PLN

A modelagem de tópicos foi validada comparando-se a capacidade discriminatória do algoritmo tradicional LDA (*Latent Dirichlet Allocation*) com a arquitetura híbrida desenvolvida (*Ensemble BERTopic + GSDMM*).

Para avaliar a acurácia semântica de forma controlada, utilizou-se como padrão-ouro (*ground truth*) as seções e editorias temáticas cadastradas historicamente pela RITA (e.g., *Engenharia de Software*, *Inteligência Artificial*, *Sistemas Distribuídos*, *Teoria da*

Computação, Processamento Gráfico e Imagens).

Os resultados empíricos demonstraram que:

- O modelo LDA clássico obteve acurácia de apenas **43,2%**, sofrendo com a sobreposição de palavras-chave genéricas e baixa coerência semântica ($C_V = 0,38$) em razão da brevidade dos resumos;
- O *ensemble* proposto alcançou **66,8% de acurácia global**, com coerência semântica substancialmente superior ($C_V = 0,62$) e diversidade temática assegurada ($RBO > 0,78$), demonstrando a eficácia da combinação entre representações contextuais densas e a suposição *one-topic-per-document* do GSDMM.

O motor de rotulagem por IA (*GenAI Naming Engine*) sintetizou as listas de palavras-chave consensuais em títulos acadêmicos concisos, eliminando a ambiguidade na interpretação dos agrupamentos. Os tópicos unificados foram então mapeados no Diagrama Estratégico de Callon, conforme ilustrado na Figura ??.

5.5 Mapeamento Topológico de Redes e Fluxo Longitudinal (Sankey)

A análise estrutural de redes identificou a microestrutura intelectual da revista. O resolvidor de referências (`format_ref_label`) converteu com sucesso mais de 98% das chaves alfanuméricas brutas do OpenAlex e DOIs em rótulos no padrão “*Autor (Ano) - Título*”, permitindo uma inspeção visual fluida no grafo HTML5 renderizado pelo Pyvis.

A detecção de comunidades via Modularidade de Louvain ($Q = 0,68$) segmentou o acervo em colégios invisíveis bem delimitados, revelando grupos coesos de pesquisadores e obras seminais frequentemente co-citadas.

Na perspectiva longitudinal, o módulo de Fluxo Temático particionou o histórico da revista em eras balanceadas por volume documental (`pd.qcut`), aplicando fatoração NMF e rastreamento de transição via Coeficiente de Jaccard ($J \geq 0,18$).

5.6 Auditoria de Governança Editorial e Conformidade Regulatória

A auditoria de governança editorial foi executada confrontando o rol de afiliações dos autores da RITA com o vínculo institucional da universidade mantenedora (UFRGS), parametrizando o teto regulatório de 20% estabelecido pelo SciELO Brasil.

O diagnóstico revelou a trajetória de internacionalização e descentralização da revista:

- Nos primeiros volumes do periódico (década de 1990), o índice de endogenia institucional atingia picos de até 38%, refletindo o caráter inicial de divulgação da produção local;
- Ao longo dos últimos dez anos, a taxa média de endogenia estabilizou-se em 12,4%, operando com margem de segurança regulatória positiva ($\Delta_{\text{reg}} = +7,6\%$) e confirmando a conformidade do veículo com os critérios de admissão de indexadores internacionais.

5.7 Validação do Protocolo de Triagem PRISMA 2020

A esteira de triagem foi testada simulando um protocolo de Mapeamento Sistemático da Literatura (SMS). A importação combinada de três arquivos com sobreposição parcial resultou na identificação automática de duplicatas sem discrepâncias numéricas.

A compilação dinâmica do diagrama em linguagem DOT gerou o fluxograma PRISMA 2020 com alinhamento horizontal estrito (`{rank=same}`), garantindo rastreabilidade desde a identificação bruta até o conjunto final de inclusão.

5.8 Síntese Comparativa frente ao Estado da Arte

Para consolidar as contribuições técnicas e funcionais da plataforma em relação aos principais softwares cienciométricos da literatura (VOSviewer, Bibliometrix, CiteSpace e SciMAT), a Tabela 5.1 apresenta uma matriz comparativa multidimensional.

A consolidação das capacidades analíticas em um ambiente único e reativo elimina a fragmentação metodológica historicamente observada no domínio cienciométrico, fornecendo a pesquisadores e conselhos editoriais uma ferramenta transparente, escalável e matematicamente auditada.

Tabela 5.1: Matriz consolidada de funcionalidades e suporte decisório frente ao estado da arte.

Dimensão Analítica	VOSviewer (ECK; WALT-MAN, 2010)	Bibliometrix (ARIA; CUC-CURULLO, 2017)	CiteSpace (CHEN, 2006)	SciMAT (COBO et al., 2012)	Solução Desenvolvida
Ingestão de Dados	Apenas WoS/S-copus estruturados	CSV / BibTeX com risco de OOM	Formatos proprietários rígidos	Módulos de migração manual	Agnóstica: CSV, Excel, BibTeX, RIS e NBIB (PubMed).
Enriquecimento de Metadados	Inexistente	Inexistente	Inexistente	Inexistente	Motor Multi-Tier em 5 níveis (OpenAlex, Crossref, PubMed, S2).
Auditoria de Integridade	Nula (processamento cego)	Nula	Nula	Nula	Painel gráfico de lacunas com exportação seletiva de erros.
Métricas de Impacto e Desigualdade	Apenas contagens simples	h -index, g -index e m -quotient	Centralidade intermediária	Métricas de rede	Índices h e g, Curva de Lorenz e Coeficiente de Gini.
Modelagem de Tópicos (PLN)	Coocorrência de palavras (BoW)	Coocorrência e LDA clássico	Burst detection e co-palavras	Análise de co-termos	Ensemble neural BERTopic + GSDMM com rotulagem via GenAI.
Redes Topológicas e Interatividade	Visualização estática (VOS)	visNetwork em R (alta latência)	Grafos estáticos sobrepostos	Redes temáticas em períodos	Grafos HTML5 interativos (Pyvis) com física contínua e 5 centralidades.
Evolução Longitudinal	Apenas sobreposição de anos	Gráficos temporais estáticos	Linhas de tempo e burst clusters	Diagramas de evolução temporal	Fatiamento dinâmico por quantis e Diagrama de Sankey (Plotly).
Governança e Endogenia	Inexistente	Inexistente	Inexistente	Inexistente	Cálculo automatizado de taxa de endogenia e concentração de coautorias.

6 CONSIDERAÇÕES FINAIS E TRABALHOS FUTUROS

6.1 Conclusões

Este trabalho apresentou o desenvolvimento e validação de uma solução computacional unificada de suporte à decisão e análise cienciométrica para periódicos acadêmicos e revisões sistemáticas de literatura. Ao estender o ecossistema prototípico de Asano, Sánchez and Thom (2026), a solução proposta superou gargalos críticos de memória, dependência de ferramentas comerciais e lentidão em dutos síncronos de enriquecimento via OpenAlex.

A segmentação arquitetural em três camadas independentes comprovou sua eficácia técnica no estudo de caso da RITA, viabilizando o processamento de algoritmos avançados de NLP, detecção de comunidades e auditorias de governança sem degradar a estabilidade do hardware do usuário. O artefato democratiza o acesso a análises cienciométricas de alto nível, conferindo autonomia a conselhos editoriais e pesquisadores.

6.2 Limitações

Dentre as limitações identificadas ao longo do projeto, destacam-se:

- A dependência de preenchimento mínimo dos metadados nos arquivos brutos para que o pareamento com a API do OpenAlex atinja alta acurácia;
- As restrições intrínsecas a classificadores probabilísticos de prenomes para inferência de gênero frente a nomes abreviados ou de origem não-ocidental;
- A necessidade de intervenção humana na parametrização inicial do assistente PRISMA para critérios qualitativos de inclusão e exclusão.

6.3 Trabalhos Futuros

Como perspectivas de continuidade e expansão do artefato computacional, destacam-se:

1. **Implementação Plena do Recomendador de Pareceristas (*Reviewer Matcher*):**
Finalizar e calibrar o algoritmo de similaridade semântica por cosseno sobre repre-

sentações vetoriais densas de manuscritos recém-submetidos;


2. **Refinamento do Classificador Demográfico:** Incorporar bases nominais complementares (como dados do IBGE para o contexto brasileiro) para mitigar a taxa de prenomes indefinidos;
3. **Integração com Plataformas Editoriais:** Desenvolver plugins de exportação e integração direta com o sistema *Open Journal Systems* (OJS), automatizando a auditoria de fascículos em tempo real.

6.4 Instruções: Figuras e tabelas

Esta seção faz referência às Figuras 6.1, 6.2, a título de exemplo. A primeira figura apresenta a estrutura de uma figura. A *descrição* deve aparecer **acima** da figura. Abaixo da figura, deve ser indicado a origem da imagem, mesmo se essa for apenas os autores do texto.

A Figura 6.2 exemplifica o uso do environment `picture`, para desenhar usando o próprio $\text{\LaTeX}$.


Figura 6.1: Descrição da Figura deve ir no topo



Fonte: Os Autores

Tabelas são construídas com praticamente os mesmos comandos. Ver a tabela 6.1.

Figura 6.2: Exemplo de figura desenhada com o environment `picture`.



Fonte: Os Autores

Tabela 6.1: Uma tabela de Exemplo

<i>Col 1</i>	<i>Col 2</i>	<i>Col 3</i>
Val 1	Val 2	Esta coluna funciona como um parágrafo, tendo uma margem definida em 5cm. Quebras de linha funcionam como em qualquer parágrafo do tex.
Valor Longo	Val 2	Val 3

Fonte: Os Autores

6.4.1 Formato de Figuras

O LaTeX permite utilizar vários formatos de figuras, entre eles *eps*, *pdf*, *jpeg* e *png*. Programas de diagramação como Inkscape (e mesmo LibreOffice) permitem gerar arquivos de imagens vetoriais que podem ser utilizados pelo LaTeX sem dificuldade. Pacotes externos permitem utilizar SVG e outros formatos.

Dia e xfig são programas utilizados por dinossauros para gerar figuras vetoriais. Se possível, evite-os.

6.4.2 Classificação dos etc.

O formato adotado pela ABNT prevê apenas três níveis (capítulo, seção e subseção). Assim, `\subsubsection` não é aconselhado.

6.5 Instruções: Sobre as referências bibliográficas

A classe *iiufrgs* faz uso do pacote *abnTeX2* com algumas alterações feitas por Sandro Rama Fiorini. Culpe ele se algo der errado. Agradeça a ele pelo que der certo. As modificações dão uma camada de tinta NATBIB-style, já que o *abntex2* usa uns comandos de citação feitos para alienígenas de 5 braços wtf. Exemplos de citação:

- *cite*: Unicórnios são verdes (PICENI; ALEXANDRE; BALREIRA, 2025);
- *citep*: Unicórnios são verdes (PICENI; ALEXANDRE; BALREIRA, 2025);
- *citet*: Segundo Piceni, Alexandre and Balreira (2025), unicórnios são verdes.
- *citen or citenum*: Segundo Piceni, Alexandre and Balreira (2025), unicórnios são

verdes.

- *citeauthor e citeyearpar*: Segundo artigos de PICENI; ALEXANDRE; BALREIRA, unicórnios são verdes (2025).

O estilo abnt fornecido antigamente pelo UTUG não é mais recomendado, pois não produz saída de acordo com as exigências da biblioteca.

Recomenda-se o uso de bibtex para gerenciar as referências (veja o arquivo biblio.bib).

REFERÊNCIAS

- ALBALAWI, R.; YEAP, T. H.; BENYOUNCEF, M. Using topic modeling methods for short-text data: A comparative analysis. **Frontiers in Artificial Intelligence**, v. 3, p. 42, Jul 2020. Available from Internet: <<https://doi.org/10.3389/frai.2020.00042>>.
- ALBARRÁN, P. et al. The skewness of science in 219 sub-fields and a number of aggregates. **Scientometrics**, v. 88, n. 2, p. 385–397, 2011.
- AMORIM, A. et al. Modelagem de tópicos em textos curtos: uma avaliação experimental. In: **Anais do XXXVII Simpósio Brasileiro de Bancos de Dados**. Porto Alegre, RS, Brasil: SBC, 2022. p. 254–266. ISSN 2763-8979. Available from Internet: <<https://sol.sbc.org.br/index.php/sbbd/article/view/21811>>.
- ARIA, M.; CUCCURULLO, C. bibliometrix: An r-tool for comprehensive science mapping analysis. **Journal of Informetrics**, v. 11, n. 4, p. 959–975, 2017.
- ASANO, L. N.; SÁNCHEZ, E. S.; THOM, L. H. Simplifying bibliometric analysis with python streamlit. **Anais do Simpósio Brasileiro de Sistemas de Informação (SBSI)**, 2026. Available from Internet: <<https://sol.sbc.org.br/index.php/sbsi/article/view/41352>>.
- BLEI, D. M. Probabilistic topic models. **Communications of the ACM**, v. 55, n. 4, p. 77–84, 2012.
- BLEI, D. M.; NG, A. Y.; JORDAN, M. I. Latent dirichlet allocation. **J. Mach. Learn. Res.**, JMLR.org, v. 3, p. 993–1022, 2003. ISSN 1532-4435. Available from Internet: <<http://portal.acm.org/citation.cfm?id=944937>>.
- BLONDEL, V. D. et al. Fast unfolding of communities in large networks. **Journal of Statistical Mechanics: Theory and Experiment**, v. 2008, n. 10, p. P10008, 2008.
- BRANDES, U. A faster algorithm for betweenness centrality. **Journal of Mathematical Sociology**, Taylor & Francis, v. 25, n. 2, p. 163–177, 2001.
- CALLON, M. et al. From translations to problematic networks: An introduction to co-word analysis. **Social Science Information**, v. 22, n. 2, p. 191–235, 1983.
- CHEN, C. CiteSpace II: Detecting and visualizing emerging trends and transient patterns in scientific literature. **Journal of the American Society for Information Science and Technology**, v. 57, n. 3, p. 359–377, 2006.
- CHURCHILL, R.; SINGH, L. The evolution of topic modeling. **ACM Comput. Surv.**, Association for Computing Machinery, New York, NY, USA, v. 54, n. 10s, nov. 2022. ISSN 0360-0300. Available from Internet: <<https://doi.org/10.1145/3507900>>.
- COBO, M. et al. Scimat: A new science mapping analysis software tool. **Journal of the American Society for Information Science and Technology**, v. 63, p. 1609–1630, 07 2012.
- COBO, M. J. et al. An approach for detecting, quantifying, and visualizing the evolution of a research field: A practical application to the fuzzy sets theory field. **Journal of Informetrics**, v. 5, n. 1, p. 146–166, 2011.

DONTHU, N. et al. How to conduct a bibliometric analysis: An overview and guidelines. **Journal of Business Research**, v. 133, p. 285–296, 2021.

ECK, N. J. van; WALTMAN, L. Software survey: VOSviewer, a computer program for bibliometric mapping. **Scientometrics**, v. 84, n. 2, p. 523–538, 2010.

EGGHE, L. Theory and practise of the g-index. **Scientometrics**, v. 69, n. 1, p. 131–152, 2006.

FREEMAN, L. C. Centrality in social networks conceptual clarification. **Social Networks**, Elsevier, v. 1, n. 3, p. 215–239, 1978.

FRUCHTERMAN, T. M. J.; REINGOLD, E. M. Graph drawing by force-directed placement. **Software: Practice and Experience**, v. 21, n. 11, p. 1129–1164, 1991.

GARFIELD, E. Citation analysis as a tool in journal evaluation. **Science**, v. 178, n. 4060, p. 471–479, 1972.

GINI, C. **Variabilità e mutabilità: contributo allo studio delle distribuzioni e delle relazioni statistiche**. Bologna: Tipografia di Cuppini, 1912.

GROOTENDORST, M. Bertopic: Neural topic modeling with a class-based tf-idf procedure. **arXiv preprint arXiv:2203.05794**, 2022.

HIRSCH, J. E. An index to quantify an individual's scientific research output. **Proceedings of the National Academy of Sciences**, v. 102, n. 46, p. 16569–16572, 2005.

HOLMAN, L.; STUART-FOX, D.; HAUSER, C. The gender gap in science: How long until women are equally represented? **PLoS Biology**, v. 16, n. 4, p. e2004956, 2018.

JACCARD, P. Étude comparative de la distribution florale dans une portion des alpes et des jura. **Bulletin de la Société Vaudoise des Sciences Naturelles**, v. 37, p. 547–579, 1901.

KESSLER, M. M. Bibliographic coupling between scientific papers. **American Documentation**, v. 14, n. 1, p. 10–25, 1963.

KHANDELWAL, T. **Using LLM-Based Approaches to Enhance and Automate Topic Labeling**. 2025. Available from Internet: <<https://arxiv.org/abs/2502.18469>>.

KITCHENHAM, B. et al. Systematic literature reviews in software engineering – a systematic literature review. **Information and Software Technology**, v. 51, n. 1, p. 7–15, 2009.

LEE, D. D.; SEUNG, H. S. Learning the parts of objects by non-negative matrix factorization. **Nature**, Nature Publishing Group, v. 401, n. 6755, p. 788–791, 1999.

LORENZ, M. O. Methods of measuring the concentration of wealth. **Publications of the American Statistical Association**, v. 9, n. 70, p. 209–219, 1905.

MARZIALE, M. H. P. Editorial endogeneity and the internationalization of scientific journals. **Revista Latino-Americana de Enfermagem**, v. 22, n. 5, p. 711–712, 2014. Available from Internet: <<https://scielo.br>>.

MCINNES, L.; HEALY, J.; ASTELS, S. hdbscan: Hierarchical density based clustering. **Journal of Open Source Software**, v. 2, n. 11, p. 205, 2017.

MCINNES, L.; HEALY, J.; MELVILLE, J. Umap: Uniform manifold approximation and projection for dimension reduction. **arXiv preprint arXiv:1802.03426**, 2018.

MINUZZO, T. et al. Women in business process management: a systematic mapping. **SBC Computing Reviews**, v. 20, p. 1–18, 2026.

MORAL-MUNOZ, J. et al. Software tools for conducting bibliometric analysis in science: An up-to-date review. **El Profesional de la Información**, v. 29, 01 2020.

NAZAROVETS, M.; NAZAROVETS, S. Prevention of endogamy in the editorial boards of university journals. **Journal of Academic Ethics**, v. 24, n. 1, p. 1, oct 2025. ISSN 1572-8544. Available from Internet: <<https://doi.org/10.1007/s10805-025-09687-z>>.

PAGE, L. et al. The pagerank citation ranking : Bringing order to the web. In: **The Web Conference**. [s.n.], 1999. Available from Internet: <<https://api.semanticscholar.org/CorpusID:1508503>>.

PAGE, M. J. et al. The prisma 2020 statement: an updated guideline for reporting systematic reviews. **BMJ**, v. 372, p. n71, 2021.

PEFFERS, K. et al. A design science research methodology for information systems research. **Journal of Management Information Systems**, v. 24, n. 3, p. 45–77, 2007.

PETERSEN, K. et al. Systematic mapping studies in software engineering. In: **12th International Conference on Evaluation and Assessment in Software Engineering (EASE)**. [S.l.: s.n.], 2008. p. 1–10.

PETERSEN, K.; VAKKALANKA, S.; KUZNIARZ, L. Guidelines for conducting systematic mapping studies in software engineering: An update. **Information and Software Technology**, Elsevier, v. 64, p. 1–18, 2015.

PICENI, H.; ALEXANDRE, P.; BALREIRA, D. A música brasileira na ditadura militar: uma análise de tópicos com bertopic e gsdtmm. In: **Anais do XVI Simpósio Brasileiro de Tecnologia da Informação e da Linguagem Humana**. Porto Alegre, RS, Brasil: SBC, 2025. p. 349–360. ISSN 0000-0000. Available from Internet: <<https://sol.sbc.org.br/index.php/stil/article/view/37837>>.

PINTO, A. et al. Endogamia académica en revistas de biblioteconomía y ciencias de la información. **Revista Interamericana de Bibliotecología**, v. 47, n. 2, p. e355413, abr. 2024. Available from Internet: <<https://revistas.udea.edu.co/index.php/RIB/article/view/355413>>.

PRANCKUTÈ, R. Web of science (wos) and scopus: The titans of bibliographic information in today's academic world. **Publications**, v. 9, n. 1, 2021. ISSN 2304-6775. Available from Internet: <<https://www.mdpi.com/2304-6775/9/1/12>>.

PRIEM, J.; PIWOWAR, H.; ORR, R. Openalex: A fully-open index of scholarly works, authors, venues, institutions, and concepts. **arXiv preprint arXiv:2205.01833**, 2022.

RÖDER, M.; BOTH, A.; HINNEBURG, A. Exploring the space of topic coherence measures. In: **Proceedings of the Eighth ACM International Conference on Web Search and Data Mining (WSDM)**. [S.l.: s.n.], 2015. p. 399–408.

SANTAMARÍA, L.; MIHALJEVIĆ, H. Comparison and benchmark of name-to-gender inference services. **PeerJ Computer Science**, v. 2018, p. e156, 2018.

SciELO. **Critérios, política e procedimentos para a admissão e a permanência de periódicos na Coleção SciELO Brasil**. São Paulo, 2020. Available from Internet: <<https://www.scielo.br>>.

SMALL, H. Co-citation in the scientific literature: A new measure of the relationship between two documents. **Journal of the American Society for Information Science**, v. 24, n. 4, p. 265–269, 1973.

STUMPF, I. R. C. Periódicos científicos brasileiros: estratégias para sua sobrevivência. **Ciência da Informação**, v. 25, n. 3, p. 1–7, 1996. Available from Internet: <<http://revista.ibict.br/ciinf/article/view/637>>.

TRUONG, B. Q.; NGUYEN-DUC, A.; VAN, N. T. C. A quantitative review of the research on business process management in digital transformation: A bibliometric approach. **Software**, v. 2, n. 3, p. 377–399, 2023. ISSN 2674-113X. Available from Internet: <<https://www.mdpi.com/2674-113X/2/3/18>>.

WEBBER, W.; MOFFAT, A.; ZOBEL, J. A similarity measure for indefinite rankings. **ACM Transactions on Information Systems (TOIS)**, ACM New York, NY, USA, v. 28, n. 4, p. 1–38, 2010.

YIN, J.; WANG, J. A dirichlet multinomial mixture model-based approach for short text clustering. In: **Proceedings of the 20th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining**. [S.l.: s.n.], 2014. p. 233–242.